

Метод Монте-Карло, Временные различия

Алексей Скрынник

ПЛАН


- 01 Метод Монте-Карло
- 02 Метод временных различий
- 03 Q-обучение
- 04 Обобщенный подход
- 05 Переход между TD и МК методами

01

Метод Монте-Карло

Обновление динамического программирования

Какое основное ограничение есть у методов динамического программирования?



Итерация по полезностям

```
1: Инициализировать  $V(s)$  произвольно для всех  $s \in \mathcal{S}$ 
2: repeat
3:    $\Delta \leftarrow 0$ 
4:   for каждый  $s \in \mathcal{S}$  do
5:      $v \leftarrow V(s)$ 
6:      $V(s) \leftarrow \max_a \sum_{s',r} p(s', r|s, a)[r + \gamma V(s')]$ 
7:      $\Delta \leftarrow \max(\Delta, |v - V(s)|)$ 
8:   end for
9: until  $\Delta < \theta$ 
10:  $\pi(s) \leftarrow \arg \max_a \sum_{s',r} p(s', r|s, a)[r + \gamma V(s')]$ 
11: return  $\pi, V$ 
```

▷ порог сходимости

Ограничение — нам нужна внутренняя информация о среде для поиска стратегии

Монте-Карло подход к обучению с подкреплением

1. Будем оценивать стратегию напрямую по эпизодам взаимодействия со средой.
2. Используем безмодельный подход (model-free): модель переходов МППР и функция вознаграждения не известны.
3. Будем проводить обучение по полным эпизодам.
4. Подход Монте-Карло (МК) использует максимально простую идею: полезность равна средней отдаче.

Монте-Карло оценка стратегии

→ Цель: построить V^π по эпизодам взаимодействия по стратегии π :

$$s_1, a_1, r_1, \dots, s_k \sim \pi$$

→ *Отдача* (return) — это суммарное вознаграждение:

$$R_t = r_{t+1} + \gamma r_{t+2} + \dots + \gamma^{T-1} r_T$$

→ *Функция полезности* — это матожидание отдачи:

$$V^\pi(s) = \mathbb{E}_\pi[R_t | s_t = s]$$

→ Монте-Карло оценка стратегии использует **эмпирическое среднее** отдачи вместо матожидания.

Монте-Карло оценка стратегии с первым посещением

Оцениваем состояние s :

→ для **первого** по времени посещения состояния s в эпизоде:

$$\rightarrow N(s) \leftarrow N(s) + 1$$

$$\rightarrow S(s) \leftarrow S(s) + R_t$$

Полезность оцениваем как среднюю отдачу: $V(s) = S(s)/N(s)$

По закону больших чисел:

$$V(s) \xrightarrow{N(s) \rightarrow \infty} V^\pi(s)$$

Несмещенная, состоятельная оценка с высокой дисперсией.

Монте-Карло оценка стратегии с каждым посещением

Оцениваем состояние s :

→ для **каждого** по времени посещения состояния s в эпизоде:

→ $N(s) \leftarrow N(s) + 1$

→ $S(s) \leftarrow S(s) + R_t$

Полезность оцениваем как среднюю отдачу: $V(s) = S(s)/N(s)$

По закону больших чисел:

$$V(s) \xrightarrow{N(s) \rightarrow \infty} V^\pi(s)$$

Смещенная, состоятельная оценка с более низкой дисперсией.

Пример: блек-джек

→ 200 состояний:

- Текущая сумма (12–21)
- Дилер показывает карту (макс. 10 очков)
- Есть ли особая комбинация (да/нет)

→ Действия:

- **Stick:** Не получать карты
- **Twist:** Взять новую карту

→ Вознаграждения за Stick:

- +1, если сумма больше, чем у дилера
- 0, если сумма такая же
- -1, если сумма меньше


→ Вознаграждения за Twist:

- -1, если сумма > 21
- 0 иначе



Функция полезности после обучения МС

Графики для стратегии — stick, если сумма карт ≥ 20 , иначе twist.



Среднее приращений

Средние последовательности могут быть вычислены последовательно (incremental mean):

$$\begin{aligned}\mu_k &= \frac{1}{k} \sum_{j=1}^k x_j = \\ &= \frac{1}{k} \left(x_k + \sum_{j=1}^{k-1} x_j \right) = \\ &= \frac{1}{k} (x_k + (k-1)\mu_{k-1}) = \\ &= \mu_{k-1} + \frac{1}{k} (x_k - \mu_{k-1})\end{aligned}$$

Монте-Карло для приращений

- Обновим $V(s)$ с приращением (incrementally) для эпизода $s_1, a_1, r_1, \dots, s_T$
- Для каждого состояния s_t с отдачей R_t :

$$N(s_t) \leftarrow N(s_t) + 1,$$

$$V(s_t) \leftarrow V(s_t) + \frac{1}{N(s_t)}(R_t - V(s_t))$$

- В нестационарных задачах может быть полезно отслеживать текущее среднее:

$$V(s_t) \leftarrow V(s_t) + \alpha(R_t - V(s_t))$$

02



Метод временных различий

Обучение на основе временных различий

→ **Подход:**

- Используем безмодельный подход (model-free): модель переходов МППР и функция вознаграждения не известны

→ **Рассмотрение неполных эпизодов:**

- Использование бутстрепа (bootstrapping) для получения информации о оставшихся будущих шагах

→ **Метод временных различий (Temporal-Difference, TD):**

- Идея метода: приближать значение полезности на основе предыдущего приближения

Монте-Карло и временные различия

- Цель: построить V^π интерактивно (online) по эпизодам взаимодействия по стратегии π
- Монте-Карло с каждым посещением для приращений: обновляем $V(s_t)$ на основе текущей отдачи R_t

$$V(s_t) \leftarrow V(s_t) + \alpha(R_t - V(s_t))$$

- Самый простой подход временных различий: TD(0):

- обновляем на основе *ожидаемой* отдачи $r_{t+1} + \gamma V(s_{t+1})$


$$V(s_t) \leftarrow V(s_t) + \alpha(r_{t+1} + \gamma V(s_{t+1}) - V(s_t)),$$

- $r_{t+1} + \gamma V(s_{t+1})$ называется **TD показателем**,
 - $\delta_t = r_{t+1} + \gamma V(s_{t+1}) - V(s_t)$ называется **TD ошибкой**

Пример: поездка домой

Состояние	Истекшее время (мин)	Ожидаемое ост. время (мин)	Предск. общее время (мин)
Выйти из офиса	0	30	30
Начать поездку, дождь	5	35	40
Съехать с шоссе	20	15	35
Ехать за грузовиком	30	10	40
Домашняя улица	40	3	43
Зайти домой	43	0	43

Пример: Монте-Карло и временные различия



- **MC:** обновляет все предсказания в сторону фактического результата
- **TD:** обновляет каждое предсказание в сторону следующего предсказания

Смещенность и дисперсия

- Отдача $R_t = r_{t+1} + \gamma r_{t+2} + \dots + \gamma^{T-1} r_T$ является **несмещенной** оценкой для $V^\pi(s)$
- Истинный TD показатель $r_{t+1} + \gamma V^\pi(s_{t+1})$ является **несмещенной** оценкой для $V^\pi(s)$
- TD показатель $r_{t+1} + \gamma V(s_{t+1})$ является **смещенной** оценкой для $V^\pi(s)$
- TD показатель имеет **меньшую дисперсию**, чем отдача:
 - отдача зависит от *большого* количества случайных действий, переходов, вознаграждений,
 - показатель зависит только от *одного* случайного действия, перехода и вознаграждения

Преимущества и недостатки


→ **МК** обладает высокой дисперсией и нулевым смещением:

- может обучаться только на полных эпизодах,
- работает только в эпизодических окружениях,
- хорошие показатели сходимости (даже без аппроксимации),
- не сильно зависит от начального приближения,
- очень прост для понимания и использования.

→ **ВР (TD)** имеет низкую дисперсию, ненулевое смещение:

- может обучаться интерактивно на каждом шаге,
- работает и для бесконечных окружений,
- обычно более эффективен, чем МК,
- TD(0) сходится к $V^\pi(s)$ (но не всегда при аппроксимации),
- более чувствителен к начальному приближению.

Пример: МК vs. ВР



Пакетные МК и ВР

- МС и TD сходятся к $V(s) \rightarrow V^\pi(s)$, если опыт $\rightarrow \infty$
- А если мы применим пакетный (batch) подход для конечного опыта?

$$s_1^1, a_1^1, r_1^1, \dots, s_{T_1}^1$$

$\vdots$

$$s_1^K, a_1^K, r_1^K, \dots, s_{T_K}^K$$

- Например, многократно выбирать эпизод $k \in [1, K]$
- Применять МС или TD(0) к эпизоду k

Пример: АВ

Два состояния А, В; нет
дисконтирования, 8 эпизодов опыта:

А, 0, В, 0

В, 1

В, 1

В, 1

В, 1

В, 1

В, 1

В, 0

Будем итеративно применять МС или
TD(0) к эпизодам. Какие значения $V(A)$
и $V(B)$?

Пример: АВ

Два состояния А, В; нет дисконтирования, 8 эпизодов опыта:

А, 0, В, 0

В, 1

В, 1

В, 1


В, 1

В, 1

В, 1

В, 0

Будем итеративно применять МС или TD(0) к эпизодам. Какие значения $V(A)$ и $V(B)$?



$$V(B) = \frac{6}{8} = 0.75$$

$$\text{МК: } V(A) = 0$$

$$\text{TD: } V(A) = 0.75$$

Эквивалентность

→ **МК** сходится к решению с минимальной среднеквадратичной ошибкой

→ Наилучшее приближение к наблюдаемой отдаче:

$$\sum_{k=1}^K \sum_{t=1}^{T_k} (R_t^k - V(s_t^k))^2$$

→ Для АВ примера $V(A) = 0$

→ **TD(0)** сходится к решению максимально правдоподобной марковской модели

→ Решение для МППР $\langle S, A, \hat{\mathcal{P}}, \hat{\mathcal{R}}, \gamma \rangle$:

$$\hat{\mathcal{P}}_{ss'}^a = \frac{1}{N(s, a)} \sum_{k=1}^K \sum_{t=1}^{T_k} \mathbf{1}(s_t^k, a_t^k, s_{t+1}^k = s, a, s')$$

$$\hat{\mathcal{R}}_s^a = \frac{1}{N(s, a)} \sum_{k=1}^K \sum_{t=1}^{T_k} \mathbf{1}(s_t^k, a_t^k = s, a) r_t^k$$

→ Для АВ примера $V(A) = 0.75$

03


Q-обучение

Безмодельное предсказание по актуальному и отложенному опыту

- **Безмодельное предсказание** (model-free prediction): оценка функции полезности по неизвестному МППР
- **Безмодельное управление** (model-free control): оптимизация функции полезности по неизвестному МППР
- Обучение **по актуальному опыту** (on-policy):
 - «обучение по ходу дела»,
 - обучение стратегии π по опыту, полученном на основе π
- Обучение **по отложенному опыту** (off-policy):
 - «обучение на чужих ошибках»,
 - обучение стратегии π по опыту, полученному на основе μ

Напоминание: Обобщенные итерации по стратегиям

- **Итеративная оценка стратегии** — вычисление V^π
- **Улучшение стратегии** — генерация $\pi' \geq \pi$



Использование функции полезности действий

→ Жадное улучшение стратегии по $V(s)$ требует знания модели МППР:

$$\pi'(s) = \arg \max_{a \in A} (\mathcal{R}_s^a + \mathcal{P}_{ss'}^a V(s'))$$

→ Жадное обновление стратегии по $Q(s, a)$ **не требует** знания модели:

$$\pi'(s) = \arg \max_{a \in A} Q(s, a)$$

Пример жадного выбора действий

Перед вами две двери:

- Открываете левую дверь:
вознаграждение 0 $\Rightarrow V(left) = 0$
- Открываете правую дверь: +1
 $\Rightarrow V(right) = 1$
- Открываете правую дверь: +2
 $\Rightarrow V(right) = 2$
- Открываете правую дверь: +2
 $\Rightarrow V(right) = 2$
- ...

Вы уверены, что выбирали лучшую дверь?



Исследование

- Простейшая идея, обеспечивающее постоянное исследование среды
- Все действия выбираются с ненулевой вероятностью
- С вероятностью $1 - \epsilon$ выбираем действие жадно
- С вероятностью ϵ выбираем действие случайно

$$\pi(a|s) = \begin{cases} \epsilon/m + 1 - \epsilon, & \text{если } a^* = \arg \max_{a \in A} Q(s, a), \\ \epsilon/m, & \text{иначе} \end{cases}$$

где $m = |A|$ — количество доступных действий.

Q-обновление

$$Q^{new}(s_t, a_t) \leftarrow (1 - \underbrace{\alpha}_{\text{скор. обуч.}}) \cdot \underbrace{Q(s_t, a_t)}_{\text{тек. значение}} + \underbrace{\alpha}_{\text{скор. обуч.}} \cdot \left(\underbrace{r_t}_{\text{вознагр.}} + \underbrace{\gamma}_{\text{дисконт.}} \cdot \underbrace{\max_a Q(s_{t+1}, a)}_{\text{оценка будущего}} \right)$$

Обучение по отложенному опыту (off-policy)

Строим целевую стратегию $\pi(a|s)$ для вычисления $V^\pi(s)$ или $Q^\pi(s, a)$ по следующей поведенческой стратегии $\mu(a|s)$:

$$(s_t, a_t, r_t, \dots) \sim \mu.$$

- Обучение по наблюдениям за человеком или другими агентами
- Переиспользование опыта, полученного по старым стратегиям $\pi_1, \pi_2, \dots, \pi_{t-1}$
- Конструирование *оптимальной* стратегии, следуя *поисковой* стратегии

Q-обучение

- Действие a_t выбирается по поведенческой стратегии $\mu(\cdot|s_t)$
- Но для оценки полезности в следующем состоянии мы возьмем альтернативное действие по целевой стратегии $a' \sim \pi(\cdot|s_t)$
- Тогда обновление $Q(s_t, a_t)$ в соответствии с полезностью альтернативного действия будет выглядеть как:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha(r_{t+1} + \gamma Q(s_{t+1}, a') - Q(s_t, a_t))$$

Управление по отложенному опыту с Q-обучением

→ Будем улучшать как целевую, так и поведенческую стратегии

→ Целевая стратегия π улучшается жадно с учетом $Q(s, a)$:

$$\pi(s_{t+1}) = \arg \max_{a'} Q(s_{t+1}, a')$$

→ Поведенческая стратегия μ , например, ϵ -жадно, также с учетом $Q(s, a)$.

→ Показатель Q-обучения упрощается:

$$\begin{aligned} & r_{t+1} + \gamma Q(s_{t+1}, a') \\ &= r_{t+1} + \gamma Q(s_{t+1}, \arg \max_{a'} Q(s_{t+1}, a')) \\ &= r_{t+1} + \max_{a'} \gamma Q(s_{t+1}, a') \end{aligned}$$

SARSA — обучение по актуальному опыту (on-policy)

```
1:  $MDP = \langle S, A, \gamma \rangle$ 
2:  $Q \leftarrow [0, \dots]$ 
3: for all эпизодов do
4:    $s$  — начальное состояние
5:    $a \leftarrow \epsilon$ -жадная  $\pi(s)$ 
6:   for all шагов эпизода do
7:      $r, s' \leftarrow$  применение  $a$ 
8:      $a' \leftarrow \epsilon$ -жадная  $\pi(s')$ 
9:      $Q[s, a] \leftarrow Q(s, a) + \alpha(r + \gamma Q[s', a'] - Q[s, a])$ 
10:     $s \leftarrow s', a \leftarrow a'$ 
11:   end for
12: end for
```

▷ задача МППР
▷ таблица значений полезности действий



Псевдокод алгоритма Q-обучения

```
1:  $MDP = \langle S, A, \gamma \rangle$ 
2:  $Q \leftarrow [0, \dots]$ 
3: for all эпизодов do
4:    $s$  — начальное состояние
5:   for all шагов эпизода do
6:      $a \leftarrow \epsilon$ -жадная  $\pi(s)$ 
7:      $r, s' \leftarrow$  применение  $a$ 
8:      $a' \leftarrow \epsilon$ -жадная  $\pi(s')$ 
9:      $Q[s, a] \leftarrow Q[s, a] + \alpha(r + \gamma \max_{a'} Q[s', a'] - Q[s, a])$ 
10:     $s \leftarrow s', a \leftarrow a'$ 
11:   end for
12: end for
```

▷ задача МППР

▷ таблица значений полезности действий

Пример задачи: Cliff Walking




04

Обобщенный подход

Монте-Карло обновление

МС обновление использует полный путь от корня до терминального состояния (одна выборочная траектория).


$$V(s_t) \leftarrow V(s_t) + \alpha(R_t - V(s_t)).$$



Обновление временных различий

TD обновление использует только один шаг: от s_t к s_{t+1} с вознаграждением r_{t+1} .


$$V(s_t) \leftarrow V(s_t) + \alpha (r_{t+1} + \gamma V(s_{t+1}) - V(s_t)).$$



Обновление динамического программирования


DP обновление использует полное ожидание по всем возможным действиям и переходам.

$$V(s_t) \leftarrow \mathbb{E}_\pi [r_{t+1} + \gamma V(s_{t+1})].$$



Обобщенный подход к обучению с подкреплением


- Методы обучения с подкреплением различаются по глубине и ширине обновлений.
- По вертикали — глубина бутстрепа: от одного шага (TD) до полного эпизода (MC).
- По горизонтали — ширина выборки обновления: от одной траектории (TD) до полного обхода по всем (DP).



05

Переход между TD и МК методами

Следы приемлимости (Eligibility Traces)





Алгоритм TD(λ)

Смесь TD-обновлений и МК, контролируемая параметром λ . $\lambda = 0$ — TD, $\lambda = 1$ — МК.

```
1: Инициализировать  $V(s)$  произвольно,  $E(s) \leftarrow 0$  для всех  $s$ 
2: Выбрать  $\alpha, \gamma, \lambda$ 
3: repeat
4:   Инициализировать состояние  $S$ 
5:   repeat
6:     Выбрать  $A$  на основе  $V$ , наблюдать  $R, S'$ 
7:      $\delta \leftarrow R + \gamma V(S') - V(S)$ 
8:      $E(S) \leftarrow E(S) + 1$ 
9:     for all states  $s$  do
10:       $V(s) \leftarrow V(s) + \alpha \delta E(s)$ 
11:       $E(s) \leftarrow \gamma \lambda E(s)$ 
12:   end for
13:    $S \leftarrow S'$ 
14: until  $S$  is terminal
15: until сходимость
```

Что дальше?

Нейросетевая аппроксимация



Вопросы?