

Непрерывное пространство действий

Алексей Скрынник

ПЛАН

01 Мотивация

02 DDPG

03 Twin Delayed DDPG

04 Soft Actor-Critic

01



Мотивация

Зачем непрерывное пространство действий?

Вопрос: почему дискретных действий недостаточно?

Зачем непрерывное пространство действий?

Вопрос: почему дискретных действий недостаточно?

Задачи с непрерывным управлением:

- **Робототехника:** углы и моменты в суставах, усилия захвата
- **Автономное вождение:** угол руля, газ, тормоз
- **Энергетика:** управление мощностью турбин, HVAC-системы
- **Финансы:** размер позиции (доля портфеля)

Зачем непрерывное пространство действий?

Вопрос: почему дискретных действий недостаточно?

Задачи с непрерывным управлением:

- **Робототехника:** углы и моменты в суставах, усилия захвата
- **Автономное вождение:** угол руля, газ, тормоз
- **Энергетика:** управление мощностью турбин, HVAC-системы
- **Финансы:** размер позиции (доля портфеля)

Проблема дискретизации:

- Число комбинаций растёт **экспоненциально**: k уровней $\times d$ измерений $= k^d$
- Робот с 7 суставами, 10 уровней на каждый $\Rightarrow 10^7$ действий
- Грубая дискретизация $\Rightarrow$ потеря точности управления


От on-policy к off-policy актор-критик

- Мы изучили on-policy PG: VPG, A2C, PPO — теперь **off-policy актор-критик** для непрерывного управления
- Почему off-policy? **Лучшая эффективность выборки:** переиспользуем данные через replay buffer

От on-policy к off-policy актер-критик

- Мы изучили on-policy PG: VPG, A2C, PPO — теперь **off-policy актер-критик** для непрерывного управления
- Почему off-policy? **Лучшая эффективность выборки:** переиспользуем данные через replay buffer

Наш план: DDPG → TD3 → SAC (возрастающая сложность)



Проблема $\arg\max$ в непрерывных пространствах

Дискретные действия (DQN):

- $a^* = \arg \max_a Q^*(s, a)$
- Перебрать все действия — тривиально

Проблема $\arg\max$ в непрерывных пространствах

Дискретные действия (DQN):

- $a^* = \arg \max_a Q^*(s, a)$
- Перебрать все действия — тривиально

Непрерывные действия:

- Невозможно перебрать все $a \in \mathbb{R}^d$
- $\max_a Q^*(s, a)$ — вычислительно сложно

Проблема $\arg\max$ в непрерывных пространствах

Дискретные действия (DQN):

- $a^* = \arg \max_a Q^*(s, a)$
- Перебрать все действия — тривиально

Непрерывные действия:

- Невозможно перебрать все $a \in \mathbb{R}^d$
- $\max_a Q^*(s, a)$ — вычислительно сложно

Два подхода:

1. **Детерминированная стратегия:** $\mu_\theta(s) \approx \arg \max_a Q(s, a)$ (DDPG, TD3)
2. **Стохастическая + энтропия:** $\pi_\theta(a|s)$ максимизирует $Q + \alpha H$ (SAC)

Предположение: $Q(s, a)$ **дифференцируема по a**

От argmax к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_a Q(s, a)$$

От $\arg\max$ к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_a Q(s, a)$$

Проблема: решать такую оптимизационную задачу заново для каждого состояния **дорого и неудобно**

От argmax к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_a Q(s, a)$$

Проблема: решать такую оптимизационную задачу заново для каждого состояния **дорого и неудобно**

Идея: заменить внутреннюю оптимизацию обучаемой функцией

$$\mu_\theta(s) \approx a^*(s)$$

От $\arg\max$ к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_a Q(s, a)$$

Проблема: решать такую оптимизационную задачу заново для каждого состояния **дорого и неудобно**

Идея: заменить внутреннюю оптимизацию обучаемой функцией

$$\mu_\theta(s) \approx a^*(s)$$

Тогда цель актора:

$$\max_{\theta} \mathbb{E}_{s \sim d^\mu} [Q^\mu(s, \mu_\theta(s))]$$

От $\arg\max$ к детерминированной стратегии

Что мы хотим в идеале?

$$a^*(s) = \arg \max_a Q(s, a)$$

Проблема: решать такую оптимизационную задачу заново для каждого состояния **дорого и неудобно**

Идея: заменить внутреннюю оптимизацию обучаемой функцией

$$\mu_\theta(s) \approx a^*(s)$$

Тогда цель актора:

$$\max_{\theta} \mathbb{E}_{s \sim d^\mu} [Q^\mu(s, \mu_\theta(s))]$$

Если $Q(s, a)$ дифференцируема по a , то можно:

- понять, **в какую сторону по действию** растёт Q
- передать этот сигнал через $\mu_\theta(s)$ к параметрам θ

Теорема DPG (Silver et al., 2014)

Напоминание: стохастический PGT (Лекция 5)

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{s \sim d^{\pi}, a \sim \pi} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot Q^{\pi}(s, a)]$$

Теорема DPG (Silver et al., 2014)

Напоминание: стохастический PGT (Лекция 5)

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{s \sim d^{\pi}, a \sim \pi} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot Q^{\pi}(s, a)]$$

Если стратегия детерминированная $a = \mu_{\theta}(s)$, то

$$\nabla_{\theta} J(\mu_{\theta}) = \mathbb{E}_{s \sim d^{\mu}} [\nabla_{\theta} Q^{\mu}(s, \mu_{\theta}(s))]$$

Теорема DPG (Silver et al., 2014)

Напоминание: стохастический PGT (Лекция 5)

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{s \sim d^{\pi}, a \sim \pi} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot Q^{\pi}(s, a)]$$

Если стратегия детерминированная $a = \mu_{\theta}(s)$, то

$$\nabla_{\theta} J(\mu_{\theta}) = \mathbb{E}_{s \sim d^{\mu}} [\nabla_{\theta} Q^{\mu}(s, \mu_{\theta}(s))]$$

Применяем цепное правило:

$$= \mathbb{E}_{s \sim d^{\mu}} \left[\nabla_a Q^{\mu}(s, a) \Big|_{a=\mu(s)} \cdot \nabla_{\theta} \mu_{\theta}(s) \right]$$

Теорема DPG (Silver et al., 2014)

Напоминание: стохастический PGT (Лекция 5)

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{s \sim d^{\pi}, a \sim \pi} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot Q^{\pi}(s, a)]$$

Если стратегия детерминированная $a = \mu_{\theta}(s)$, то

$$\nabla_{\theta} J(\mu_{\theta}) = \mathbb{E}_{s \sim d^{\mu}} [\nabla_{\theta} Q^{\mu}(s, \mu_{\theta}(s))]$$

Применяем цепное правило:

$$= \mathbb{E}_{s \sim d^{\mu}} \left[\nabla_a Q^{\mu}(s, a) \Big|_{a=\mu(s)} \cdot \nabla_{\theta} \mu_{\theta}(s) \right]$$

- $\mu_{\theta}(s)$ — **дифференцируемое приближение** $\arg \max_a Q(s, a)$
- Нет усреднения по действиям $\Rightarrow$ **меньше дисперсия**
- $\nabla_a Q$ улучшает действие, а $\nabla_{\theta} \mu_{\theta}$ переносит сигнал в параметры

02



DDPG

Deep Deterministic Policy Gradient

Критик: почти как в DQN

$$y_{\text{DQN}} = r + \gamma(1 - d) \max_{a'} Q_{\phi_{\text{targ}}}(s', a')$$

$$y_{\text{DDPG}} = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$$

$$L(\phi) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[\left(Q_{\phi}(s, a) - y_{\text{DDPG}} \right)^2 \right]$$

Deep Deterministic Policy Gradient

Критик: почти как в DQN

$$y_{\text{DQN}} = r + \gamma(1 - d) \max_{a'} Q_{\phi_{\text{targ}}}(s', a')$$

$$y_{\text{DDPG}} = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$$

$$L(\phi) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[\left(Q_{\phi}(s, a) - y_{\text{DDPG}} \right)^2 \right]$$

Ключевая замена: вместо $\max_{a'}$ используем
target actor $\mu_{\theta_{\text{targ}}}(s')$

Deep Deterministic Policy Gradient

Критик: почти как в DQN

$$y_{\text{DQN}} = r + \gamma(1 - d) \max_{a'} Q_{\phi_{\text{targ}}}(s', a')$$

$$y_{\text{DDPG}} = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$$


$$L(\phi) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[\left(Q_{\phi}(s, a) - y_{\text{DDPG}} \right)^2 \right]$$

Ключевая замена: вместо $\max_{a'}$ используем **target actor** $\mu_{\theta_{\text{targ}}}(s')$

Актор — максимизация Q-функции (из теоремы DPG):

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}} [Q_{\phi}(s, \mu_{\theta}(s))]$$

Параметры ϕ рассматриваются как **константы** при обновлении стратегии



Стабилизация обучения в DDPG

Replay buffer и target сети — как в DQN (Лекция 4).

Практическое отличие DDPG: target сети обновляем **мягко**, а не жёстким копированием

Стабилизация обучения в DDPG

Replay buffer и target сети — как в DQN (Лекция 4).

Практическое отличие DDPG: target сети обновляем **мягко**, а не жёстким копированием

DQN: периодически копируем параметры целевой сети

Стабилизация обучения в DDPG

Replay buffer и target сети — как в DQN (Лекция 4).

Практическое отличие DDPG: target сети обновляем **мягко**, а не жёстким копированием

DQN: периодически копируем параметры целевой сети

DDPG: усреднение Поляка (Polyak averaging)

$$\phi_{\text{targ}} \leftarrow \rho \phi_{\text{targ}} + (1 - \rho) \phi \quad \theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$$

где $\rho \approx 0.995$

Стабилизация обучения в DDPG

Replay buffer и target сети — как в DQN (Лекция 4).

Практическое отличие DDPG: target сети обновляем **мягко**, а не жёстким копированием

DQN: периодически копируем параметры целевой сети

DDPG: усреднение Поляка (Polyak averaging)

$$\phi_{\text{targ}} \leftarrow \rho \phi_{\text{targ}} + (1 - \rho) \phi \quad \theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$$

где $\rho \approx 0.995$

Это делает цели **более плавными** и снижает нестабильность обучения

Исследование в DDPG

- Детерминированная стратегия — **нет встроенного исследования**
- Добавляем **шум** к действиям:

$$a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \quad \epsilon \sim \mathcal{N}(0, \sigma)$$

Исследование в DDPG

- Детерминированная стратегия — **нет встроенного исследования**
- Добавляем **шум** к действиям:

$$a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \quad \epsilon \sim \mathcal{N}(0, \sigma)$$

- Оригинальная статья предлагала шум Орнштейна-Уленбека, но **некоррелированный гауссовский шум** работает не хуже и проще
- Масштаб шума можно **уменьшать со временем** (опционально)

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

1: $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$

2: **repeat**

14: **until** СХОДИМОСТЬ

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

- 1: $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$
- 2: **repeat**
- 3: Получаем s , выбираем $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$
- 4: Выполняем a , получаем s', r, d ; сохраняем (s, a, r, s', d) в $\mathcal{D}$

14: **until** СХОДИМОСТЬ

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for число обновлений do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:       Обновить  $\theta$  и  $\phi$  с помощью батча  $B$ 
9:     end for
10:   end if
11: until сходимось
12:   end for
13: end if
14: until сходимось
```

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for число обновлений do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $y = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$ 
9:        $\nabla_{\phi} \frac{1}{|B|} \sum (Q_{\phi}(s, a) - y)^2$ 
10:    end for
11:  end if
12: until сходимость
```

▷ цели

▷ критик

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for число обновлений do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $y = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$ 
9:        $\nabla_{\phi} \frac{1}{|B|} \sum (Q_{\phi}(s, a) - y)^2$ 
10:       $\nabla_{\theta} \frac{1}{|B|} \sum Q_{\phi}(s, \mu_{\theta}(s))$ 
12:     end for
13:   end if
14: until СХОДИМОСТЬ
```

▷ цели
▷ критик
▷ актор

Псевдокод DDPG

Вход: параметры стратегии θ , Q-функции ϕ , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ}} \leftarrow \phi$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for число обновлений do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $y = r + \gamma(1 - d) Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$ 
9:        $\nabla_{\phi} \frac{1}{|B|} \sum (Q_{\phi}(s, a) - y)^2$ 
10:       $\nabla_{\theta} \frac{1}{|B|} \sum Q_{\phi}(s, \mu_{\theta}(s))$ 
11:       $\phi_{\text{targ}} \leftarrow \rho \phi_{\text{targ}} + (1 - \rho) \phi; \theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$ 
12:     end for
13:   end if
14: until СХОДИМОСТЬ
```

▷ цели

▷ критик

▷ актер

▷ Polyak

03

Twin Delayed DDPG

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Twin Delayed DDPG (TD3) решает это тремя методиками:

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Twin Delayed DDPG (TD3) решает это тремя методиками:

1. **Clipped Double-Q Learning:** обучаем **две** Q-функции, используем **минимум** для целей — уменьшает смещение завышения

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Twin Delayed DDPG (TD3) решает это тремя методиками:

1. **Clipped Double-Q Learning:** обучаем **две** Q-функции, используем **минимум** для целей — уменьшает смещение завышения
2. **Delayed Policy Updates:** обновляем стратегию **реже** Q-функции (1:2) — снижает нестабильность

Ограничения DDPG и три методики TD3

- DDPG **неустойчив** к гиперпараметрам; ключевая проблема — **завышение оценок Q-функции, т.е. переоценка полезностей**

Twin Delayed DDPG (TD3) решает это тремя методиками:

1. **Clipped Double-Q Learning:** обучаем **две** Q-функции, используем **минимум** для целей — уменьшает смещение завышения
2. **Delayed Policy Updates:** обновляем стратегию **реже** Q-функции (1:2) — снижает нестабильность
3. **Target Policy Smoothing:** добавляем шум к целевому действию — сглаживает пики Q-функции

Ключевые уравнения TD3

1. Clipped Double-Q: в цели берём **минимум** двух target Q-сетей

Ключевые уравнения TD3

- 1. Clipped Double-Q:** в цели берём **минимум** двух target Q-сетей
- 2. Delayed Policy Updates:** стратегию обновляем реже критика (подробно на следующем слайде)

Ключевые уравнения TD3

- 1. Clipped Double-Q:** в цели берём **минимум** двух target Q-сетей
- 2. Delayed Policy Updates:** стратегию обновляем реже критика (подробно на следующем слайде)
- 3. Target Policy Smoothing:**

$$a'(s') = \text{clip} \left(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}} \right), \quad \tilde{\epsilon} \sim \mathcal{N}(0, \sigma)$$

Ключевые уравнения TD3

1. Clipped Double-Q: в цели берём **минимум** двух target Q-сетей

2. Delayed Policy Updates: стратегию обновляем реже критика (подробно на следующем слайде)

3. Target Policy Smoothing:

$$a'(s') = \text{clip} \left(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}} \right), \quad \tilde{\epsilon} \sim \mathcal{N}(0, \sigma)$$

Итоговая цель критика:

$$y(r, s', d) = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_i, \text{targ}}(s', a'(s'))$$

Ключевые уравнения TD3

1. Clipped Double-Q: в цели берём **минимум** двух target Q-сетей

2. Delayed Policy Updates: стратегию обновляем реже критика (подробно на следующем слайде)

3. Target Policy Smoothing:

$$a'(s') = \text{clip} \left(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}} \right), \quad \tilde{\epsilon} \sim \mathcal{N}(0, \sigma)$$

Итоговая цель критика:

$$y(r, s', d) = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_i, \text{targ}}(s', a'(s'))$$

Функции потерь для каждой Q-сети ($i = 1, 2$):

$$L(\phi_i, \mathcal{D}) = \mathbb{E}_{(s, a, r, s', d) \sim \mathcal{D}} \left[(Q_{\phi_i}(s, a) - y(r, s', d))^2 \right]$$

Обучение стратегии в TD3

2. Delayed Policy Updates

- Стратегия обучается путём **максимизации Q-функции** (как в DDPG):

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}} [Q_{\phi_1}(s, \mu_{\theta}(s))]$$

Обучение стратегии в TD3

2. Delayed Policy Updates

- Стратегия обучается путём **максимизации Q-функции** (как в DDPG):

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}} [Q_{\phi_1}(s, \mu_{\theta}(s))]$$

- Ключевое отличие: стратегия обновляется **реже** Q-функций
- Это **снижает нестабильность обучения**, вызванную быстрыми изменениями целей

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

1: $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$ для $i = 1, 2$
2: **repeat**

17: **until** СХОДИМОСТЬ

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

- 1: $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$ для $i = 1, 2$
- 2: **repeat**
- 3: Получаем s , выбираем $a = \text{clip}(\mu_\theta(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$
- 4: Выполняем a , получаем s', r, d ; сохраняем (s, a, r, s', d) в $\mathcal{D}$

17: **until** СХОДИМОСТЬ

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_\theta(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 

15:     end for
16:   end if
17: until СХОДИМОСТЬ
```

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $a'(s') = \text{clip}(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}})$  ▷ сглаживание
9:        $y = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', a'(s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
15:     end for
16:   end if
17: until СХОДИМОСТЬ
```

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $a'(s') = \text{clip}(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}})$  ▷ сглаживание
9:        $y = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', a'(s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:      if  $j \bmod \text{policy\_delay} = 0$  then ▷ отложенное обновление
12:         $\nabla_{\theta} \frac{1}{|B|} \sum Q_{\phi_1}(s, \mu_{\theta}(s))$  ▷ актор
14:      end if
15:    end for
16:  end if
17: until СХОДИМОСТЬ
```

Псевдокод TD3

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\theta_{\text{targ}} \leftarrow \theta, \phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a = \text{clip}(\mu_{\theta}(s) + \epsilon, a_{\text{low}}, a_{\text{high}}), \epsilon \sim \mathcal{N}$ 
4:   Выполняем  $a$ , получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $a'(s') = \text{clip}(\mu_{\theta_{\text{targ}}}(s') + \text{clip}(\tilde{\epsilon}, -c, c), a_{\text{low}}, a_{\text{high}})$  ▷ сглаживание
9:        $y = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', a'(s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:      if  $j \bmod \text{policy\_delay} = 0$  then ▷ отложенное обновление
12:         $\nabla_{\theta} \frac{1}{|B|} \sum Q_{\phi_1}(s, \mu_{\theta}(s))$  ▷ актор
13:         $\phi_{\text{targ},i} \leftarrow \rho \phi_{\text{targ},i} + (1 - \rho) \phi_i; \theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$  ▷ Polyak
14:      end if
15:    end for
16:  end if
17: until СХОДИМОСТЬ
```

04

Soft Actor-Critic

Soft Actor-Critic (SAC)

- SAC заполняет разрыв между стохастической оптимизацией градиента стратегии и подходами в стиле DDPG
- Включает метод **clipped double-Q** (как TD3)

Soft Actor-Critic (SAC)

- SAC заполняет разрыв между стохастической оптимизацией градиента стратегии и подходами в стиле DDPG
- Включает метод **clipped double-Q** (как TD3)
- Ключевая особенность — **энтропийная регуляризация**:
 - Стратегия максимизирует **вознаграждение + энтропию**
 - Больше энтропии $\Rightarrow$ больше исследования $\Rightarrow$ быстрее обучение
 - Предотвращает преждевременную сходимость к локальному оптимуму

Энтропия

- Энтропия показывает, насколько **случайна** случайная величина:
 - Смещённая монета (почти всегда орёл) — **низкая энтропия**
 - Сбалансированная монета — **высокая энтропия**

Энтропия

- Энтропия показывает, насколько **случайна** случайная величина:
 - Смещённая монета (почти всегда орёл) — **низкая энтропия**
 - Сбалансированная монета — **высокая энтропия**

Для случайной величины x с распределением P :

$$H(P) = \mathbb{E}_{x \sim P} [-\log P(x)]$$

Энтропия

- Энтропия показывает, насколько **случайна** случайная величина:
 - Смещённая монета (почти всегда орёл) — **низкая энтропия**
 - Сбалансированная монета — **высокая энтропия**

Для случайной величины x с распределением P :

$$H(P) = \mathbb{E}_{x \sim P} [-\log P(x)]$$

Энтропийно-регуляризованная задача RL:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t \left(r(s_t, a_t, s_{t+1}) + \alpha H(\pi(\cdot | s_t)) \right) \right]$$

где $\alpha > 0$ — коэффициент температуры

Мягкие функции полезности и уравнение Беллмана

V^π и Q^π включают энтропийные бонусы; их связь:

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$

Мягкие функции полезности и уравнение Беллмана

V^π и Q^π включают энтропийные бонусы; их связь:

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$

Мягкое уравнение Беллмана для Q^π :

$$Q^\pi(s, a) = \mathbb{E}_{s' \sim P, a' \sim \pi} [r(s, a, s') + \gamma (Q^\pi(s', a') - \alpha \log \pi(a'|s'))]$$

Мягкие функции полезности и уравнение Беллмана

V^π и Q^π включают энтропийные бонусы; их связь:

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$

Мягкое уравнение Беллмана для Q^π :

$$Q^\pi(s, a) = \mathbb{E}_{s' \sim P, a' \sim \pi} [r(s, a, s') + \gamma (Q^\pi(s', a') - \alpha \log \pi(a'|s'))]$$

Аппроксимация выборкой:

$$Q^\pi(s, a) \approx r + \gamma (Q^\pi(s', \tilde{a}') - \alpha \log \pi(\tilde{a}'|s')), \quad \tilde{a}' \sim \pi(\cdot|s')$$

Обучение стратегии в SAC

- Стратегия максимизирует

$$V^{\pi}(s) = \mathbb{E}_{a \sim \pi} [Q^{\pi}(s, a) - \alpha \log \pi(a|s)]$$

Обучение стратегии в SAC


- Стратегия максимизирует

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$

Трюк с репараметризацией: выборка из π_θ через детерминированную функцию:

$$\tilde{a}_\theta(s, \xi) = \tanh(\mu_\theta(s) + \sigma_\theta(s) \odot \xi), \quad \xi \sim \mathcal{N}(0, I)$$

Здесь сеть задаёт $\mu_\theta(s)$ и $\sigma_\theta(s)$
(на практике обычно параметризуют через $\log \sigma_\theta(s)$, $\sigma_\theta(s) = \exp(\log \sigma_\theta(s))$)



Обучение стратегии в SAC

► Стратегия максимизирует

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a|s)]$$


Трюк с репараметризацией: выборка из π_θ через детерминированную функцию:

$$\tilde{a}_\theta(s, \xi) = \tanh(\mu_\theta(s) + \sigma_\theta(s) \odot \xi), \quad \xi \sim \mathcal{N}(0, I)$$

Здесь сеть задаёт $\mu_\theta(s)$ и $\sigma_\theta(s)$
(на практике обычно параметризуют через $\log \sigma_\theta(s)$, $\sigma_\theta(s) = \exp(\log \sigma_\theta(s))$)

Функция потерь стратегии (с min-double-Q):

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}, \xi \sim \mathcal{N}} \left[\min_{j=1,2} Q_{\phi_j}(s, \tilde{a}_\theta(s, \xi)) - \alpha \log \pi_\theta(\tilde{a}_\theta(s, \xi)|s) \right]$$



Ключевые отличия стратегии SAC

1. **Функция сжатия $\tanh$:**

- Гарантирует ограниченный диапазон действий
- Отсутствует в VPG, TRPO, PPO
- Изменяет распределение: до $\tanh$ — гауссова, после — нет

Ключевые отличия стратегии SAC

1. **Функция сжатия $\tanh$:**

- Гарантирует ограниченный диапазон действий
- Отсутствует в VPG, TRPO, PPO
- Изменяет распределение: до $\tanh$ — гауссова, после — нет

2. **Зависящие от состояния σ :**

- В VPG/TRPO/PPO: $\log \sigma$ — фиксированный вектор параметров
- В SAC: $\log \sigma_{\theta}(s)$ — выход нейронной сети (зависит от s)

SAC и TD3: сходства и различия

Сходства с TD3:

- Две Q-функции (MSBE)
- Target сети (Polyak)
- Clipped double-Q

SAC и TD3: сходства и различия

Сходства с TD3:

- Две Q-функции (MSBE)
- Target сети (Polyak)
- Clipped double-Q

Отличия от TD3:

- Цель включает **энтропийный** член
- Действия из **текущей** стратегии (не целевой)
- **Стохастическая** стратегия (нет явного сглаживания)
- Авто-настройка α

SAC и TD3: сходства и различия

Сходства с TD3:

- Две Q-функции (MSBE)
- Target сети (Polyak)
- Clipped double-Q

Отличия от TD3:

- Цель включает **энтропийный** член
- Действия из **текущей** стратегии (не целевой)
- **Стохастическая** стратегия (нет явного сглаживания)
- Авто-настройка α

Функция потерь в SAC:

$$L(\phi_i, \mathcal{D}) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[(Q_{\phi_i}(s,a) - y(r,s',d))^2 \right], \quad y = r + \gamma(1-d) \left(\min_{j=1,2} Q_{\phi_{\text{targ},j}}(s', \tilde{a}') - \alpha \log \pi_{\theta}(\tilde{a}'|s') \right)$$

Автоматическая настройка температуры α

- **SAC v1:** α — фиксированный гиперпараметр

Автоматическая настройка температуры α

- **SAC v1:** α — фиксированный гиперпараметр
- **SAC v2:** подбираем α так, чтобы удерживать нужную энтропию стратегии

Целевая постановка:

$$\max_{\pi} \mathbb{E} \left[\sum_t \gamma^t r_t \right] \quad \text{при} \quad \mathbb{E}_{a \sim \pi(\cdot | s_t)} [-\log \pi(a | s_t)] \geq \mathcal{H}_{\text{target}} \quad \forall t$$

Автоматическая настройка температуры α

- **SAC v1:** α — фиксированный гиперпараметр
- **SAC v2:** подбираем α так, чтобы удерживать нужную энтропию стратегии

Целевая постановка:

$$\max_{\pi} \mathbb{E} \left[\sum_t \gamma^t r_t \right] \quad \text{при} \quad \mathbb{E}_{a \sim \pi(\cdot|s_t)} [-\log \pi(a|s_t)] \geq \mathcal{H}_{\text{target}} \quad \forall t$$

Двойственная задача по α :

$$\alpha^* = \arg \min_{\alpha > 0} \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_{\theta}(\cdot|s)} [-\alpha \log \pi_{\theta}(a|s) - \alpha \mathcal{H}_{\text{target}}]$$

$$\mathcal{H}_{\text{target}} = -\dim(\mathcal{A})$$

Автоматическая настройка температуры α

- **SAC v1:** α — фиксированный гиперпараметр
- **SAC v2:** подбираем α так, чтобы удерживать нужную энтропию стратегии

Целевая постановка:

$$\max_{\pi} \mathbb{E} \left[\sum_t \gamma^t r_t \right] \quad \text{при} \quad \mathbb{E}_{a \sim \pi(\cdot|s_t)} [-\log \pi(a|s_t)] \geq \mathcal{H}_{\text{target}} \quad \forall t$$

Двойственная задача по α :

$$\alpha^* = \arg \min_{\alpha > 0} \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_{\theta}(\cdot|s)} [-\alpha \log \pi_{\theta}(a|s) - \alpha \mathcal{H}_{\text{target}}]$$

$$\mathcal{H}_{\text{target}} = -\dim(\mathcal{A})$$

Почему не напрямую?

- Простая минимизация по α дала бы $\alpha = 0$
- Поэтому α здесь — множитель Лагранжа, а не свободный вес

Эквивалентный взгляд: KL-регуляризация

SAC можно записать как

$$\max_{\pi} \mathbb{E}[Q(s, a)] - \alpha (\pi(\cdot|s) \parallel \rho(\cdot))$$

Эквивалентный взгляд: KL-регуляризация

SAC можно записать как

$$\max_{\pi} \mathbb{E}[Q(s, a)] - \alpha (\pi(\cdot|s) \parallel \rho(\cdot))$$

Если $\rho(\cdot)$ равномерно на $\mathcal{A}$, то

$$(\pi \parallel \rho) = \mathbb{E}_{a \sim \pi} [\log \pi(a|s) - \log \rho(a)] = -H(\pi(\cdot|s)) + \text{const}$$

Эквивалентный взгляд: KL-регуляризация

SAC можно записать как

$$\max_{\pi} \mathbb{E}[Q(s, a)] - \alpha (\pi(\cdot|s) \parallel \rho(\cdot))$$

Если $\rho(\cdot)$ равномерно на $\mathcal{A}$, то

$$(\pi \parallel \rho) = \mathbb{E}_{a \sim \pi} [\log \pi(a|s) - \log \rho(a)] = -H(\pi(\cdot|s)) + \text{const}$$

Тогда

$$\mathbb{E}[Q(s, a)] - \alpha (\pi \parallel \rho) \equiv \mathbb{E}[Q(s, a)] + \alpha H(\pi)$$

Эквивалентный взгляд: KL-регуляризация

SAC можно записать как

$$\max_{\pi} \mathbb{E}[Q(s, a)] - \alpha (\pi(\cdot|s) \parallel \rho(\cdot))$$

Если $\rho(\cdot)$ равномерно на $\mathcal{A}$, то

$$(\pi \parallel \rho) = \mathbb{E}_{a \sim \pi} [\log \pi(a|s) - \log \rho(a)] = -H(\pi(\cdot|s)) + \text{const}$$

Тогда

$$\mathbb{E}[Q(s, a)] - \alpha (\pi \parallel \rho) \equiv \mathbb{E}[Q(s, a)] + \alpha H(\pi)$$

- Энтропийная формулировка SAC — частный случай KL-регуляризации
- Адаптивная α задаёт силу притяжения к высокоэнтропийному ориентиру

Как α влияет на стратегию

$$\max_{\pi} \mathbb{E}[Q(s, a) - \alpha \log \pi(a|s)] = \mathbb{E}[Q(s, a)] + \alpha H(\pi)$$

Большое α :

- больше вес энтропии
- стратегия шире и случайнее
- больше исследования

Как α влияет на стратегию

$$\max_{\pi} \mathbb{E}[Q(s, a) - \alpha \log \pi(a|s)] = \mathbb{E}[Q(s, a)] + \alpha H(\pi)$$

Большое α :

- больше вес энтропии
- стратегия шире и случайнее
- больше исследования

Малое α :

- больше вес $Q(s, a)$
- стратегия острее и жаднее
- ближе к детерминированной

Как α влияет на стратегию

$$\max_{\pi} \mathbb{E}[Q(s, a) - \alpha \log \pi(a|s)] = \mathbb{E}[Q(s, a)] + \alpha H(\pi)$$

Большое α :

- больше вес энтропии
- стратегия шире и случайнее
- больше исследования

Малое α :

- больше вес $Q(s, a)$
- стратегия острее и жаднее
- ближе к детерминированной

Если $\alpha = 0$: энтропийный бонус исчезает, и SAC теряет идею max-entropy RL

Практическая настройка α

- Для continuous SAC берём эвристику $\mathcal{H}_{\text{target}} = -\dim(\mathcal{A})$
- На батче состояний сэмплируем $a \sim \pi_{\theta}(\cdot|s)$ и считаем $\log \pi_{\theta}(a|s)$
- Обновляем α отдельным шагом

Практическая настройка α

- Для continuous SAC берём эвристику $\mathcal{H}_{\text{target}} = -\dim(\mathcal{A})$
- На батче состояний сэмплируем $a \sim \pi_{\theta}(\cdot|s)$ и считаем $\log \pi_{\theta}(a|s)$
- Обновляем α отдельным шагом

Текущая энтропия:

$$\mathcal{H}_{\text{cur}} = \mathbb{E}[-\log \pi_{\theta}(a|s)]$$

Практическая настройка α

- Для continuous SAC берём эвристику $\mathcal{H}_{\text{target}} = -\dim(\mathcal{A})$
- На батче состояний сэмплируем $a \sim \pi_{\theta}(\cdot|s)$ и считаем $\log \pi_{\theta}(a|s)$
- Обновляем α отдельным шагом

Текущая энтропия:

$$\mathcal{H}_{\text{cur}} = \mathbb{E} [-\log \pi_{\theta}(a|s)]$$

$$L_{\alpha} = \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_{\theta}(\cdot|s)} [-\alpha (\log \pi_{\theta}(a|s) + \mathcal{H}_{\text{target}})]$$

Практическая настройка α

- Для continuous SAC берём эвристику $\mathcal{H}_{\text{target}} = -\dim(\mathcal{A})$
- На батче состояний сэмплируем $a \sim \pi_{\theta}(\cdot|s)$ и считаем $\log \pi_{\theta}(a|s)$
- Обновляем α отдельным шагом

Текущая энтропия:

$$\mathcal{H}_{\text{cur}} = \mathbb{E} [-\log \pi_{\theta}(a|s)]$$

$$L_{\alpha} = \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_{\theta}(\cdot|s)} [-\alpha (\log \pi_{\theta}(a|s) + \mathcal{H}_{\text{target}})]$$

- Если $\mathcal{H}_{\text{cur}} < \mathcal{H}_{\text{target}}$, то α увеличивается
- Если $\mathcal{H}_{\text{cur}} > \mathcal{H}_{\text{target}}$, то α уменьшается

Практическая настройка α

- Для continuous SAC берём эвристику $\mathcal{H}_{\text{target}} = -\dim(\mathcal{A})$
- На батче состояний сэмплируем $a \sim \pi_{\theta}(\cdot|s)$ и считаем $\log \pi_{\theta}(a|s)$
- Обновляем α отдельным шагом

Текущая энтропия:

$$\mathcal{H}_{\text{cur}} = \mathbb{E} [-\log \pi_{\theta}(a|s)]$$

$$L_{\alpha} = \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_{\theta}(\cdot|s)} [-\alpha (\log \pi_{\theta}(a|s) + \mathcal{H}_{\text{target}})]$$

- Если $\mathcal{H}_{\text{cur}} < \mathcal{H}_{\text{target}}$, то α увеличивается
- Если $\mathcal{H}_{\text{cur}} > \mathcal{H}_{\text{target}}$, то α уменьшается

В train loop: critic $\rightarrow$ actor $\rightarrow$ update α

(обычно на том же батче)

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

1: $\phi_{\text{targ},i} \leftarrow \phi_i$ для $i = 1, 2$

2: **repeat**

16: **until** СХОДИМОСТЬ

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

- 1: $\phi_{\text{targ},i} \leftarrow \phi_i$ для $i = 1, 2$
- 2: **repeat**
- 3: Получаем s , выбираем $a \sim \pi_\theta(\cdot|s)$, выполняем a
- 4: Получаем s', r, d ; сохраняем (s, a, r, s', d) в $\mathcal{D}$

16: **until** СХОДИМОСТЬ

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 

14:    end for
15:  end if
16: until СХОДИМОСТЬ
```

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл из текущей стратегии
9:        $y = r + \gamma(1 - d)(\min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
14:     end for
15:   end if
16: until СХОДИМОСТЬ
```

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл из текущей стратегии
9:        $y = r + \gamma(1 - d)(\min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:       $\nabla_{\theta} \frac{1}{|B|} \sum (\min_{i=1,2} Q_{\phi_i}(s, \tilde{a}_\theta) - \alpha \log \pi_\theta(\tilde{a}_\theta|s))$  ▷ актер
14:   end for
15: end if
16: until СХОДИМОСТЬ
```

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл из текущей стратегии
9:        $y = r + \gamma(1 - d)(\min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:       $\nabla_{\theta} \frac{1}{|B|} \sum (\min_{i=1,2} Q_{\phi_i}(s, \tilde{a}_\theta) - \alpha \log \pi_\theta(\tilde{a}_\theta|s))$  ▷ актер
12:       $\alpha \leftarrow \alpha - \lambda_\alpha \nabla_\alpha \frac{1}{|B|} \sum (-\alpha \log \pi_\theta(\tilde{a}|s) - \alpha \mathcal{H}_{\text{target}})$  ▷ авто- $\alpha$ 
14:     end for
15:   end if
16: until СХОДИМОСТЬ
```

Псевдокод SAC

Вход: параметры стратегии θ , Q-функций ϕ_1, ϕ_2 , пустой буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B = \{(s, a, r, s', d)\}$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл из текущей стратегии
9:        $y = r + \gamma(1 - d)(\min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$  ▷ цели
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2, i = 1, 2$  ▷ критик
11:       $\nabla_{\theta} \frac{1}{|B|} \sum (\min_{i=1,2} Q_{\phi_i}(s, \tilde{a}_\theta) - \alpha \log \pi_\theta(\tilde{a}_\theta|s))$  ▷ актер
12:       $\alpha \leftarrow \alpha - \lambda_\alpha \nabla_{\alpha} \frac{1}{|B|} \sum (-\alpha \log \pi_\theta(\tilde{a}|s) - \alpha \mathcal{H}_{\text{target}})$  ▷ авто- $\alpha$ 
13:       $\phi_{\text{targ},i} \leftarrow \rho \phi_{\text{targ},i} + (1 - \rho) \phi_i, i = 1, 2$  ▷ Polyak
14:     end for
15:   end if
16: until СХОДИМОСТЬ
```

Сравнение: DDPG vs TD3 vs SAC

	DDPG	TD3	SAC
Стратегия	детерм.	детерм.	стохаст.
Исследование	внешний шум	внешний шум	энтропия
Q-сети	1	2	2
Целевая сеть актора	да	да	нет
Отлож. обновления	нет	да	нет
Ключевая идея	DPG + replay	3 стабилизации	max-ent RL

Сравнение: DDPG vs TD3 vs SAC

	DDPG	TD3	SAC
Стратегия	детерм.	детерм.	стохаст.
Исследование	внешний шум	внешний шум	энтропия
Q-сети	1	2	2
Целевая сеть актора	да	да	нет
Отлож. обновления	нет	да	нет
Ключевая идея	DPG + replay	3 стабилизации	max-ent RL

Рекомендации:

- **SAC** — рекомендация по умолчанию (робастность, исследование)
- **TD3** — сильная альтернатива
- **DDPG** — только как baseline

Практические рекомендации

Типичные гиперпараметры (SAC / TD3):

- Learning rate: 3×10^{-4} (Adam), batch size: 256
- Replay buffer: 10^6 переходов, Polyak $\rho = 0.995$
- Начало обучения: после 10^4 случайных шагов (заполнение буфера)

Практические рекомендации

Типичные гиперпараметры (SAC / TD3):

- Learning rate: 3×10^{-4} (Adam), batch size: 256
- Replay buffer: 10^6 переходов, Polyak $\rho = 0.995$
- Начало обучения: после 10^4 случайных шагов (заполнение буфера)

Частые ошибки:

- Отсутствие **нормализации наблюдений** (running mean/std)
- Неправильное **масштабирование наград** (слишком большие $\Rightarrow$ взрыв Q)
- Игнорирование **границ действий** (clip / tanh)
- Слишком маленький буфер или слишком ранний старт обучения

Вопросы?

SAC для дискретных действий

Вопрос: как адаптировать SAC для **дискретного** пространства действий?

Подсказки:

1. Что заменяет гауссово распределение?
2. Нужен ли трюк с репараметризацией, если можно перебрать все действия?
3. Как изменится функция потерь актора?
4. Как точно вычислить энтропию $H(\pi(\cdot|s))$?

Вход: θ, ϕ_1, ϕ_2 , буфер $\mathcal{D}$

```
1:  $\phi_{\text{targ},i} \leftarrow \phi_i$  для  $i = 1, 2$ 
2: repeat
3:   Получаем  $s$ , выбираем  $a \sim \pi_\theta(\cdot|s)$ , выполняем  $a$ 
4:   Получаем  $s', r, d$ ; сохраняем  $(s, a, r, s', d)$  в  $\mathcal{D}$ 
5:   if пора обновлять then
6:     for  $j = 1, 2, \dots$  do
7:       Батч  $B$  из  $\mathcal{D}$ 
8:        $\tilde{a}' \sim \pi_\theta(\cdot|s')$  ▷ сэмпл
9:        $y = r + \gamma(1 - d)(\min_i Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_\theta(\tilde{a}'|s'))$ 
10:       $\nabla_{\phi_i} \frac{1}{|B|} \sum (Q_{\phi_i}(s, a) - y)^2$  ▷ критик
11:       $\nabla_{\theta} \frac{1}{|B|} \sum (\min_i Q_{\phi_i}(s, \tilde{a}_\theta) - \alpha \log \pi_\theta(\tilde{a}_\theta|s))$  ▷ актер
12:      Обновляем  $\alpha$  ▷ авто- $\alpha$ 
13:      Polyak:  $\phi_{\text{targ},i} \leftarrow \rho \phi_{\text{targ},i} + (1 - \rho) \phi_i$ 
14:    end for
15:  end if
16: until сходимость
```