

Мультиагентное обучение с подкреплением

Алексей Скрынник

ПЛАН

- 01 Мотивация
- 02 Теория игр и модели
- 03 Классические алгоритмы
- 04 Глубокие методы MARL
- 05 Приложения

01



Мотивация

От одного агента к множеству

Ранее: МППР с одним агентом $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ (лекции 1–7)

От одного агента к множеству

Ранее: МППР с одним агентом $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ (лекции 1–7)

Что меняется при $N > 1$ агентов?

1. **Нестационарность** — другие агенты обучаются одновременно $\Rightarrow$ среда нестационарна с точки зрения каждого агента

От одного агента к множеству

Ранее: МППР с одним агентом $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ (лекции 1–7)

Что меняется при $N > 1$ агентов?

1. **Нестационарность** — другие агенты обучаются одновременно $\Rightarrow$ среда нестационарна с точки зрения каждого агента
2. **Оценка вклада** — какой агент повлиял на результат?

От одного агента к множеству

Ранее: МППР с одним агентом $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ (лекции 1–7)

Что меняется при $N > 1$ агентов?

1. **Нестационарность** — другие агенты обучаются одновременно $\Rightarrow$ среда нестационарна с точки зрения каждого агента
2. **Оценка вклада** — какой агент повлиял на результат?
3. **Равновесие vs оптимальность** — понятие «оптимальной стратегии» становится неоднозначным; нужны равновесные концепции

От одного агента к множеству

Ранее: МППР с одним агентом $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ (лекции 1–7)

Что меняется при $N > 1$ агентов?

1. **Нестационарность** — другие агенты обучаются одновременно $\Rightarrow$ среда нестационарна с точки зрения каждого агента
2. **Оценка вклада** — какой агент повлиял на результат?
3. **Равновесие vs оптимальность** — понятие «оптимальной стратегии» становится неоднозначным; нужны равновесные концепции


Multi-Agent RL (MARL) — область RL, изучающая взаимодействие нескольких обучаемых агентов в общей среде

Примеры мультиагентных задач

Примеры мультиагентных задач

Кооперация


- Роботизированные рои
- Автономное вождение
- Складская логистика



Примеры мультиагентных задач

Кооперация

- Роботизированные рои
- Автономное вождение
- Складская логистика



Конкуренция


- Настольные игры (Го, шахматы)
- Покер
- Торговые стратегии



Примеры мультиагентных задач

Кооперация

- Роботизированные рои
- Автономное вождение
- Складская логистика



Конкуренция

- Настольные игры (Го, шахматы)
- Покер
- Торговые стратегии



Смешанная

- StarCraft II
- Dota 2
- Экономические рынки



Классификация задач MARL

- **Тип взаимодействия:** кооперативные / конкурентные / смешанные
- **Наблюдаемость:** полная / частичная
- **Исполнение:** централизованное / децентрализованное
- **Агенты:** гомогенные / гетерогенные

Парадигма CTDE

Centralized Training with Decentralized Execution — доминирующая парадигма MARL:

Парадигма CTDE

Centralized Training with Decentralized Execution — доминирующая парадигма MARL:

- **Обучение (training):** агенты **могут** обмениваться информацией, использовать глобальное состояние s

Парадигма CTDE


Centralized Training with Decentralized Execution — доминирующая парадигма MARL:

- **Обучение (training):** агенты **могут** обмениваться информацией, использовать глобальное состояние s
- **Исполнение (execution):** каждый агент действует **только** по локальному наблюдению o_i

Парадигма CTDE

Centralized Training with Decentralized Execution — доминирующая парадигма MARL:

- **Обучение (training):** агенты **могут** обмениваться информацией, использовать глобальное состояние s
- **Исполнение (execution):** каждый агент действует **только** по локальному наблюдению o_i



Проблема нестационарности среды

С точки зрения агента i , остальные агенты — часть среды:

$$P(s'|s, a_i) = \sum_{\mathbf{a}_{-i}} P(s'|s, a_i, \mathbf{a}_{-i}) \prod_{j \neq i} \pi_j(a_j|o_j)$$

Проблема нестационарности среды

С точки зрения агента i , остальные агенты — часть среды:

$$P(s'|s, a_i) = \sum_{\mathbf{a}_{-i}} P(s'|s, a_i, \mathbf{a}_{-i}) \prod_{j \neq i} \pi_j(a_j|o_j)$$

Если стратегии π_j меняются (обучение) $\Rightarrow$ функция перехода **нестационарна**

$\Rightarrow$ Нарушается марковское свойство из лекции 1!

Проблема нестационарности среды

С точки зрения агента i , остальные агенты — часть среды:

$$P(s'|s, a_i) = \sum_{\mathbf{a}_{-i}} P(s'|s, a_i, \mathbf{a}_{-i}) \prod_{j \neq i} \pi_j(a_j|o_j)$$

Если стратегии π_j меняются (обучение) $\Rightarrow$ функция перехода **нестационарна**

$\Rightarrow$ Нарушается марковское свойство из лекции 1!

Пример: дилемма заключённого

	C	D
C	$-1, -1$	$-3, 0$
D	$0, -3$	$-2, -2$

Если агент 2 меняет стратегию $C \rightarrow D$, лучший ответ агента 1 тоже меняется

02



Теория игр и модели

Нормальная форма игры

Определение

Игра в нормальной форме — кортеж $\langle \mathcal{N}, \{A_i\}_{i \in \mathcal{N}}, \{u_i\}_{i \in \mathcal{N}} \rangle$, где

- ▶ $\mathcal{N} = \{1, \dots, N\}$ — множество игроков,
- ▶ A_i — множество действий (стратегий) игрока i ,
- ▶ $u_i : A_1 \times \dots \times A_N \rightarrow \mathbb{R}$ — функция полезности (выигрыш) игрока i ;
используем u_i , а не Q/V , т.к. здесь нет состояний и переходов во времени.

Нормальная форма игры

Определение

Игра в нормальной форме — кортеж $\langle \mathcal{N}, \{A_i\}_{i \in \mathcal{N}}, \{u_i\}_{i \in \mathcal{N}} \rangle$, где

- ▶ $\mathcal{N} = \{1, \dots, N\}$ — множество игроков,
- ▶ A_i — множество действий (стратегий) игрока i ,
- ▶ $u_i : A_1 \times \dots \times A_N \rightarrow \mathbb{R}$ — функция полезности (выигрыш) игрока i ;
используем u_i , а не Q/V , т.к. здесь нет состояний и переходов во времени.

Примеры:

Дилемма заключённого

	C	D
C	$-1, -1$	$-3, 0$
D	$0, -3$	$-2, -2$

Орёл и решка

	H	T
H	$+1, -1$	$-1, +1$
T	$-1, +1$	$+1, -1$

Равновесие Нэша

Определение

Профиль стратегий $(\pi_1^*, \dots, \pi_N^*)$ является *равновесием Нэша* (Nash Equilibrium, NE), если ни один игрок не может увеличить свою полезность, отклонившись в одностороннем порядке:

$$\forall i, \forall \pi'_i : u_i(\pi_i^*, \pi_{-i}^*) \geq u_i(\pi'_i, \pi_{-i}^*)$$

Равновесие Нэша

Определение

Профиль стратегий $(\pi_1^*, \dots, \pi_N^*)$ является *равновесием Нэша* (Nash Equilibrium, NE), если ни один игрок не может увеличить свою полезность, отклонившись в одностороннем порядке:

$$\forall i, \forall \pi'_i : u_i(\pi_i^*, \pi_{-i}^*) \geq u_i(\pi'_i, \pi_{-i}^*)$$

- **Чистые стратегии:** детерминированный выбор действия
- **Смешанные стратегии:** вероятностное распределение $\pi_i \in \Delta(A_i)$

Равновесие Нэша

Определение

Профиль стратегий $(\pi_1^*, \dots, \pi_N^*)$ является *равновесием Нэша* (Nash Equilibrium, NE), если ни один игрок не может увеличить свою полезность, отклонившись в одностороннем порядке:

$$\forall i, \forall \pi'_i : u_i(\pi_i^*, \pi_{-i}^*) \geq u_i(\pi'_i, \pi_{-i}^*)$$

- **Чистые стратегии:** детерминированный выбор действия
- **Смешанные стратегии:** вероятностное распределение $\pi_i \in \Delta(A_i)$

Теорема Нэш, 1950

Каждая конечная игра имеет хотя бы одно равновесие Нэша в смешанных стратегиях.

Игры с нулевой суммой и теорема минимакса

Определение

Игра с нулевой суммой: $u_1(\mathbf{a}) + u_2(\mathbf{a}) = 0$ для всех $\mathbf{a}$.

Игры с нулевой суммой и теорема минимакса

Определение

Игра с нулевой суммой: $u_1(\mathbf{a}) + u_2(\mathbf{a}) = 0$ для всех $\mathbf{a}$.

Минимаксная стратегия — наилучшая при наихудшем поведении оппонента:

$$\pi_1^* = \arg \max_{\pi_1} \min_{\pi_2} \mathbb{E}_{\pi_1, \pi_2}[u_1]$$

Игры с нулевой суммой и теорема минимакса

Определение

Игра с нулевой суммой: $u_1(\mathbf{a}) + u_2(\mathbf{a}) = 0$ для всех $\mathbf{a}$.

Минимаксная стратегия — наилучшая при наихудшем поведении оппонента:

$$\pi_1^* = \arg \max_{\pi_1} \min_{\pi_2} \mathbb{E}_{\pi_1, \pi_2}[u_1]$$

Теорема фон Нейман, 1928

В любой конечной игре с нулевой суммой:

$$\max_{\pi_1} \min_{\pi_2} \mathbb{E}[u_1] = \min_{\pi_2} \max_{\pi_1} \mathbb{E}[u_1] = v^*$$

Значение v^* — значение игры. Минимаксная стратегия является равновесием Нэша.

Игры с нулевой суммой и теорема минимакса

Определение

Игра с нулевой суммой: $u_1(\mathbf{a}) + u_2(\mathbf{a}) = 0$ для всех $\mathbf{a}$.

Минимаксная стратегия — наилучшая при наихудшем поведении оппонента:

$$\pi_1^* = \arg \max_{\pi_1} \min_{\pi_2} \mathbb{E}_{\pi_1, \pi_2}[u_1]$$

Теорема фон Нейман, 1928

В любой конечной игре с нулевой суммой:

$$\max_{\pi_1} \min_{\pi_2} \mathbb{E}[u_1] = \min_{\pi_2} \max_{\pi_1} \mathbb{E}[u_1] = v^*$$

Значение v^* — *значение игры*. Минимаксная стратегия является равновесием Нэша.

Связь с RL: в одноагентном случае $\max_{\pi} V^{\pi}(s)$ — нет оппонента; в двухагентном — $\max_{\pi_1} \min_{\pi_2}$

Экстенсивная форма игры

Расширение нормальной формы для **последовательных** игр:

- **Дерево игры** — описывает порядок ходов
- **Информационные множества** — объединяют вершины, которые игрок не может различить (неполная информация)
- **Совершенная информация:** шахматы, Го (все вершины различимы)
- **Несовершенная информация:** покер (скрытые карты)

Стохастические (марковские) игры

Определение

Стохастическая игра (Shapley, 1953) — кортеж $\langle \mathcal{N}, \mathcal{S}, \{A_i\}_{i=1}^N, \mathcal{P}, \{R_i\}_{i=1}^N, \gamma \rangle$, где

- ▶ $\mathcal{N} = \{1, \dots, N\}$ — множество агентов,
- ▶ $\mathcal{S}$ — множество состояний,
- ▶ A_i — множество действий агента i ,
- ▶ $\mathcal{P}(s' | s, a_1, \dots, a_N)$ — вероятность перехода,
- ▶ $R_i(s, a_1, \dots, a_N)$ — функция вознаграждения агента i ,
- ▶ $\gamma \in [0, 1]$ — дисконтирующий множитель.

Стохастические (марковские) игры

Определение

Стохастическая игра (Shapley, 1953) — кортеж $\langle \mathcal{N}, \mathcal{S}, \{A_i\}_{i=1}^N, \mathcal{P}, \{R_i\}_{i=1}^N, \gamma \rangle$, где

- $\mathcal{N} = \{1, \dots, N\}$ — множество агентов,
- $\mathcal{S}$ — множество состояний,
- A_i — множество действий агента i ,
- $\mathcal{P}(s' | s, a_1, \dots, a_N)$ — вероятность перехода,
- $R_i(s, a_1, \dots, a_N)$ — функция вознаграждения агента i ,
- $\gamma \in [0, 1]$ — дисконтирующий множитель.

Частные случаи:

- $N = 1 \Rightarrow$ обычный МППР (лекция 1)
- $|\mathcal{S}| = 1 \Rightarrow$ повторяющаяся матричная игра
- $R_1 + R_2 = 0 \Rightarrow$ марковская игра с нулевой суммой

Dec-POMDP и частично наблюдаемые стохастические игры

Если агенты наблюдают состояние **не полностью**:

Определение

Частично наблюдаемая стохастическая игра (POSG) расширяет стохастическую игру: $\langle \mathcal{N}, \mathcal{S}, \{A_i\}, \mathcal{P}, \{R_i\}, \{\mathcal{O}_i\}, \mathcal{Z}, \gamma \rangle$, где

- ▶ $\mathcal{O}_i$ — пространство наблюдений агента i ,
- ▶ $\mathcal{Z}(o_1, \dots, o_N | s', \mathbf{a})$ — функция наблюдений.

Dec-POMDP и частично наблюдаемые стохастические игры

Если агенты наблюдают состояние **не полностью**:

Определение

Частично наблюдаемая стохастическая игра (POSG) расширяет стохастическую игру: $\langle \mathcal{N}, \mathcal{S}, \{A_i\}, \mathcal{P}, \{R_i\}, \{\mathcal{O}_i\}, \mathcal{Z}, \gamma \rangle$, где

- ▶ $\mathcal{O}_i$ — пространство наблюдений агента i ,
- ▶ $\mathcal{Z}(o_1, \dots, o_N | s', \mathbf{a})$ — функция наблюдений.

Dec-POMDP — кооперативный частный случай: $R_1 = R_2 = \dots = R_N$ (общее вознаграждение)

Dec-POMDP и частично наблюдаемые стохастические игры

Если агенты наблюдают состояние **не полностью**:

Определение

Частично наблюдаемая стохастическая игра (POSG) расширяет стохастическую игру: $\langle \mathcal{N}, \mathcal{S}, \{A_i\}, \mathcal{P}, \{R_i\}, \{\mathcal{O}_i\}, \mathcal{Z}, \gamma \rangle$, где

- ▶ $\mathcal{O}_i$ — пространство наблюдений агента i ,
- ▶ $\mathcal{Z}(o_1, \dots, o_N | s', \mathbf{a})$ — функция наблюдений.

Dec-POMDP — кооперативный частный случай: $R_1 = R_2 = \dots = R_N$ (общее вознаграждение)

Сложность: Dec-POMDP — NEXP-полная задача (значительно сложнее POMDP)

Dec-POMDP и частично наблюдаемые стохастические игры

Если агенты наблюдают состояние **не полностью**:

Определение

Частично наблюдаемая стохастическая игра (POSG) расширяет стохастическую игру: $\langle \mathcal{N}, \mathcal{S}, \{A_i\}, \mathcal{P}, \{R_i\}, \{\mathcal{O}_i\}, \mathcal{Z}, \gamma \rangle$, где

- ▶ $\mathcal{O}_i$ — пространство наблюдений агента i ,
- ▶ $\mathcal{Z}(o_1, \dots, o_N | s', \mathbf{a})$ — функция наблюдений.

Dec-POMDP — кооперативный частный случай: $R_1 = R_2 = \dots = R_N$ (общее вознаграждение)

Сложность: Dec-POMDP — NEXP-полная задача (значительно сложнее POMDP)

Большинство практических алгоритмов MARL работают именно в этой постановке

Иерархия формальных моделей

Модель	Агенты	Состояния	Наблюд.
Матричная игра	$N \geq 2$	1	полная
MDP	1	$ \mathcal{S} \geq 1$	полная
Стохаст. игра	$N \geq 2$	$ \mathcal{S} \geq 1$	полная
POMDP	1	$ \mathcal{S} \geq 1$	частичная
Dec-POMDP / POSG	$N \geq 2$	$ \mathcal{S} \geq 1$	частичная

03

Классические алгоритмы

Independent Q-Learning (IQL)

Простейший подход: каждый агент запускает **стандартный Q-learning** (лекция 3) независимо

Independent Q-Learning (IQL)

Простейший подход: каждый агент запускает **стандартный Q-learning** (лекция 3) независимо

Агент i обновляет свою Q-функцию:

$$Q_i(s, a_i) \leftarrow Q_i(s, a_i) + \alpha [r_i + \gamma \max_{a'_i} Q_i(s', a'_i) - Q_i(s, a_i)]$$

Другие агенты рассматриваются как часть среды (игнорируются)

Independent Q-Learning (IQL)

Простейший подход: каждый агент запускает **стандартный Q-learning** (лекция 3) независимо

Агент i обновляет свою Q-функцию:

$$Q_i(s, a_i) \leftarrow Q_i(s, a_i) + \alpha [r_i + \gamma \max_{a'_i} Q_i(s', a'_i) - Q_i(s, a_i)]$$

Другие агенты рассматриваются как часть среды (игнорируются)

Проблемы:

- Нет гарантий сходимости (нестационарность!)
- Каждый агент «гоняется за тенью» — среда меняется, пока он обучается

Independent Q-Learning (IQL)

Простейший подход: каждый агент запускает **стандартный Q-learning** (лекция 3) независимо

Агент i обновляет свою Q-функцию:

$$Q_i(s, a_i) \leftarrow Q_i(s, a_i) + \alpha [r_i + \gamma \max_{a'_i} Q_i(s', a'_i) - Q_i(s, a_i)]$$

Другие агенты рассматриваются как часть среды (игнорируются)

Проблемы:

- Нет гарантий сходимости (нестационарность!)
- Каждый агент «гоняется за тенью» — среда меняется, пока он обучается

Удивительный факт: на практике IQL часто *работает*, особенно в кооперативных задачах

Fictitious Play

Классический алгоритм из теории игр (Brown, 1951):

Fictitious Play

Классический алгоритм из теории игр (Brown, 1951):

1. Каждый агент ведёт **эмпирическое распределение** действий оппонента:

$$\hat{\pi}_{-i}^{(t)}(a_{-i}) = \frac{1}{t} \sum_{\tau=1}^t \mathbf{1}[a_{-i}^{(\tau)} = a_{-i}]$$

Fictitious Play

Классический алгоритм из теории игр (Brown, 1951):

1. Каждый агент ведёт **эмпирическое распределение** действий оппонента:

$$\hat{\pi}_{-i}^{(t)}(a_{-i}) = \frac{1}{t} \sum_{\tau=1}^t \mathbf{1}[a_{-i}^{(\tau)} = a_{-i}]$$

2. Выбирает **лучший ответ** (best response) на $\hat{\pi}_{-i}^{(t)}$:

$$a_i^{(t+1)} = \arg \max_{a_i} \sum_{a_{-i}} \hat{\pi}_{-i}^{(t)}(a_{-i}) \cdot u_i(a_i, a_{-i})$$

Fictitious Play

Классический алгоритм из теории игр (Brown, 1951):

1. Каждый агент ведёт **эмпирическое распределение** действий оппонента:

$$\hat{\pi}_{-i}^{(t)}(a_{-i}) = \frac{1}{t} \sum_{\tau=1}^t \mathbf{1}[a_{-i}^{(\tau)} = a_{-i}]$$

2. Выбирает **лучший ответ** (best response) на $\hat{\pi}_{-i}^{(t)}$:

$$a_i^{(t+1)} = \arg \max_{a_i} \sum_{a_{-i}} \hat{\pi}_{-i}^{(t)}(a_{-i}) \cdot u_i(a_i, a_{-i})$$

- **Сходимость:** Гарантирована в играх с нулевой суммой и потенциальных играх
- Не гарантирована в общем случае (циклы)

Minimax-Q

Для **двуагентных игр с нулевой суммой** (Littman, 1994)

Minimax-Q

Для **двухагентных игр с нулевой суммой** (Littman, 1994)

Заменяем $\max$ в Q-learning на **минимаксный оператор**:

$$V(s) = \max_{\pi_1 \in \Delta(A_1)} \min_{a_2 \in A_2} \sum_{a_1} \pi_1(a_1) Q(s, a_1, a_2)$$

Minimax-Q

Для **двухагентных игр с нулевой суммой** (Littman, 1994)

Заменяем $\max$ в Q-learning на **минимаксный оператор**:

$$V(s) = \max_{\pi_1 \in \Delta(A_1)} \min_{a_2 \in A_2} \sum_{a_1} \pi_1(a_1) Q(s, a_1, a_2)$$

Обновление Q-функции:

$$Q(s, a_1, a_2) \leftarrow Q(s, a_1, a_2) + \alpha [r + \gamma V(s') - Q(s, a_1, a_2)]$$

где $V(s')$ вычисляется с помощью линейного программирования (LP)

Minimax-Q

Для **двухагентных игр с нулевой суммой** (Littman, 1994)

Заменяем $\max$ в Q-learning на **минимаксный оператор**:

$$V(s) = \max_{\pi_1 \in \Delta(A_1)} \min_{a_2 \in A_2} \sum_{a_1} \pi_1(a_1) Q(s, a_1, a_2)$$

Обновление Q-функции:

$$Q(s, a_1, a_2) \leftarrow Q(s, a_1, a_2) + \alpha [r + \gamma V(s') - Q(s, a_1, a_2)]$$

где $V(s')$ вычисляется с помощью линейного программирования (LP)

Свойства:

- Сходится к оптимальной стратегии в стохастических играх с нулевой суммой
- Вычислительно дороже Q-learning: LP на каждом шаге

Nash-Q Learning

Обобщение на **игры с ненулевой суммой** (Hu & Wellman, 2003)

Nash-Q Learning

Обобщение на **игры с ненулевой суммой** (Hu & Wellman, 2003)

Каждый агент поддерживает Q-функции **всех** агентов:

$$Q_i(s, a_1, \dots, a_N) \leftarrow Q_i(s, \mathbf{a}) + \alpha [r_i + \gamma \text{NE}_i(Q_1(s', \cdot), \dots, Q_N(s', \cdot)) - Q_i(s, \mathbf{a})]$$

где NE_i — значение i -го игрока в равновесии Нэша совместной матричной игры в s'

Nash-Q Learning

Обобщение на **игры с ненулевой суммой** (Hu & Wellman, 2003)

Каждый агент поддерживает Q-функции **всех** агентов:

$$Q_i(s, a_1, \dots, a_N) \leftarrow Q_i(s, \mathbf{a}) + \alpha [r_i + \gamma \text{NE}_i(Q_1(s', \cdot), \dots, Q_N(s', \cdot)) - Q_i(s, \mathbf{a})]$$

где NE_i — значение i -го игрока в равновесии Нэша совместной матричной игры в s'

Проблемы:

- Равновесие Нэша может быть **неединственным** $\Rightarrow$ какое выбрать?
- Вычисление NE — сложная задача
- Сходимость гарантирована только в особых случаях

Friend-or-Foe Q-Learning

Упрощённые варианты Nash-Q для **известного типа** игры (Littman, 2001):

Friend-or-Foe Q-Learning

Упрощённые варианты Nash-Q для **известного типа** игры (Littman, 2001):

Friend-Q (кооперация: $R_1 = R_2$):

$$V(s) = \max_{a_1, a_2} Q(s, a_1, a_2)$$

Агенты «друзья» — совместная максимизация

Friend-or-Foe Q-Learning

Упрощённые варианты Nash-Q для **известного типа** игры (Littman, 2001):

Friend-Q (кооперация: $R_1 = R_2$):

$$V(s) = \max_{a_1, a_2} Q(s, a_1, a_2)$$

Агенты «друзья» — совместная максимизация

Foe-Q (конкуренция: $R_1 = -R_2$):

$$V(s) = \max_{\pi_1} \min_{a_2} \sum_{a_1} \pi_1(a_1) Q(s, a_1, a_2)$$

Совпадает с Minimax-Q

Friend-or-Foe Q-Learning

Упрощённые варианты Nash-Q для **известного типа** игры (Littman, 2001):

Friend-Q (кооперация: $R_1 = R_2$):

$$V(s) = \max_{a_1, a_2} Q(s, a_1, a_2)$$

Агенты «друзья» — совместная максимизация

Foe-Q (конкуренция: $R_1 = -R_2$):

$$V(s) = \max_{\pi_1} \min_{a_2} \sum_{a_1} \pi_1(a_1) Q(s, a_1, a_2)$$

Совпадает с Minimax-Q

Преимущество: гарантии сходимости в обоих случаях (в отличие от общего Nash-Q)

Сравнение классических алгоритмов

	Класс игры	Оператор	Сходимость
IQL	любой	$\max_{a_i}$	нет гарантий
Fict. Play	любой	best response	нулевая сумма, потенц.
Minimax-Q	нулевая сумма	$\max \min$ (LP)	да
Nash-Q	общий	Nash (PPAD)	особые случаи
Friend-Q	кооперативный	$\max_a$	да
Foe-Q	нулевая сумма	$\max \min$ (LP)	да

Сравнение классических алгоритмов

	Класс игры	Оператор	Сходимость
IQL	любой	$\max_{a_i}$	нет гарантий
Fict. Play	любой	best response	нулевая сумма, потенц.
Minimax-Q	нулевая сумма	$\max \min$ (LP)	да
Nash-Q	общий	Nash (PPAD)	особые случаи
Friend-Q	кооперативный	$\max_a$	да
Foe-Q	нулевая сумма	$\max \min$ (LP)	да

Общая проблема: совместное пространство действий $|A_1| \times \dots \times |A_N|$ растёт **экспоненциально** с числом агентов

Ограничения табличных методов

- **Масштабируемость:** совместная Q-таблица $Q(s, a_1, \dots, a_N)$ — экспоненциальный размер

Ограничения табличных методов

- **Масштабируемость:** совместная Q-таблица $Q(s, a_1, \dots, a_N)$ — экспоненциальный размер
- **Непрерывные наблюдения:** большинство реальных задач имеют непрерывные $\mathcal{S}$ и $\mathcal{O}_i$

Ограничения табличных методов

- **Масштабируемость:** совместная Q-таблица $Q(s, a_1, \dots, a_N)$ — экспоненциальный размер
- **Непрерывные наблюдения:** большинство реальных задач имеют непрерывные $\mathcal{S}$ и $\mathcal{O}_i$
- **Частичная наблюдаемость:** табличные методы предполагают полную наблюдаемость

Ограничения табличных методов

- **Масштабируемость:** совместная Q-таблица $Q(s, a_1, \dots, a_N)$ — экспоненциальный размер
- **Непрерывные наблюдения:** большинство реальных задач имеют непрерывные $\mathcal{S}$ и $\mathcal{O}_i$
- **Частичная наблюдаемость:** табличные методы предполагают полную наблюдаемость

Выход: глубокие нейросетевые методы MARL

Ключевая идея: вместо совместной Q-таблицы — **декомпозиция** или **централизованный критик**

Аналогия с переходом от табличного Q-learning (лекция 3) к DQN (лекция 4)

04

Глубокие методы MARL

Оценка вклада агентов в кооперативных задачах

Задача: N агентов получают **общее** вознаграждение r_{team}

Кто из агентов внёс вклад?

Оценка вклада агентов в кооперативных задачах

Задача: N агентов получают **общее** вознаграждение r_{team}

Кто из агентов внёс вклад?

Наивный подход: $r_i = r_{\text{team}}$ для всех i

- Проблема «ленивого агента» — можно не действовать и получать награду за счёт других

Оценка вклада агентов в кооперативных задачах

Задача: N агентов получают **общее** вознаграждение r_{team}

Кто из агентов внёс вклад?

Наивный подход: $r_i = r_{\text{team}}$ для всех i

➤ Проблема «ленивого агента» — можно не действовать и получать награду за счёт других

Идея: разложить совместную Q-функцию $Q_{\text{tot}}(s, a_1, \dots, a_N)$ на индивидуальные $Q_i(o_i, a_i)$

Оценка вклада агентов в кооперативных задачах

Задача: N агентов получают **общее** вознаграждение r_{team}

Кто из агентов внёс вклад?

Наивный подход: $r_i = r_{\text{team}}$ для всех i

➤ Проблема «ленивого агента» — можно не действовать и получать награду за счёт других

Идея: разложить совместную Q-функцию $Q_{\text{tot}}(s, a_1, \dots, a_N)$ на индивидуальные $Q_i(o_i, a_i)$

Требование **IGM** (Individual-Global-Max):

$$\arg \max_{\mathbf{a}} Q_{\text{tot}}(\boldsymbol{\tau}, \mathbf{a}) = \begin{pmatrix} \arg \max_{a_1} Q_1(\tau_1, a_1) \\ \vdots \\ \arg \max_{a_N} Q_N(\tau_N, a_N) \end{pmatrix}$$

т.е. жадный выбор по Q_i = жадный выбор по Q_{tot}

VDN: декомпозиция суммой

Value Decomposition Networks (Sunehag et al., 2018)

VDN: декомпозиция суммой

Value Decomposition Networks (Sunehag et al., 2018)

Простейшая декомпозиция — **аддитивная**:

$$Q_{\text{tot}}(\boldsymbol{\tau}, \mathbf{a}) = \sum_{i=1}^N Q_i(\tau_i, a_i; \theta_i)$$

VDN: декомпозиция суммой

Value Decomposition Networks (Sunehag et al., 2018)

Простейшая декомпозиция — **аддитивная**:

$$Q_{\text{tot}}(\boldsymbol{\tau}, \mathbf{a}) = \sum_{i=1}^N Q_i(\tau_i, a_i; \theta_i)$$

Удовлетворяет IGM: $\arg \max_{\mathbf{a}} \sum_i Q_i = (\arg \max_{a_1} Q_1, \dots, \arg \max_{a_N} Q_N)$

VDN: декомпозиция суммой

Value Decomposition Networks (Sunehag et al., 2018)

Простейшая декомпозиция — **аддитивная**:

$$Q_{\text{tot}}(\boldsymbol{\tau}, \mathbf{a}) = \sum_{i=1}^N Q_i(\tau_i, a_i; \theta_i)$$

Удовлетворяет IGM: $\arg \max_{\mathbf{a}} \sum_i Q_i = (\arg \max_{a_1} Q_1, \dots, \arg \max_{a_N} Q_N)$

Обучение: стандартная функция потерь DQN (лекция 4) на Q_{tot} :

$$L(\theta) = \mathbb{E} \left[\left(Q_{\text{tot}} - [r + \gamma \max_{\mathbf{a}'} Q'_{\text{tot}}] \right)^2 \right]$$

Градиент проходит через сумму к каждой Q_i — end-to-end обучение

VDN: декомпозиция суммой

Value Decomposition Networks (Sunehag et al., 2018)

Простейшая декомпозиция — **аддитивная**:

$$Q_{\text{tot}}(\boldsymbol{\tau}, \mathbf{a}) = \sum_{i=1}^N Q_i(\tau_i, a_i; \theta_i)$$

Удовлетворяет IGM: $\arg \max_{\mathbf{a}} \sum_i Q_i = (\arg \max_{a_1} Q_1, \dots, \arg \max_{a_N} Q_N)$

Обучение: стандартная функция потерь DQN (лекция 4) на Q_{tot} :

$$L(\theta) = \mathbb{E} \left[\left(Q_{\text{tot}} - [r + \gamma \max_{\mathbf{a}'} Q'_{\text{tot}}] \right)^2 \right]$$

Градиент проходит через сумму к каждой Q_i — end-to-end обучение

Ограничение: аддитивность — сильное предположение; не может выразить, что совместные действия дают больше, чем сумма по отдельности

QMIX: монотонная декомпозиция

QMIX (Rashid et al., 2018) — ослабляет аддитивность VDN до **МОНОТОННОСТИ**:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_i} \geq 0 \quad \forall i$$

QMIX: монотонная декомпозиция

QMIX (Rashid et al., 2018) — ослабляет аддитивность VDN до **МОНОТОННОСТИ**:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_i} \geq 0 \quad \forall i$$

Q_{tot} — монотонная (не обязательно аддитивная) функция от $Q_1, \dots, Q_N$

Mixing network: нейросеть с **неотрицательными** весами

QMIX: монотонная декомпозиция

QMIX (Rashid et al., 2018) — ослабляет аддитивность VDN до **монотонности**:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_i} \geq 0 \quad \forall i$$

Q_{tot} — монотонная (не обязательно аддитивная) функция от $Q_1, \dots, Q_N$


Mixing network: нейросеть с **неотрицательными** весами

Гиперсеть генерирует веса mixing network из глобального состояния s :

$$w = |f_{\text{hyper}}(s)|, \quad b = g_{\text{hyper}}(s)$$

$|\cdot|$ гарантирует неотрицательность весов

QMIX: архитектура



VDN vs QMIX: ограничения монотонности

QMIX строго выразительнее VDN, но **монотонность** всё же ограничивает:

VDN vs QMIX: ограничения монотонности

QMIX строго выразительнее VDN, но **монотонность** всё же ограничивает:

Контрпример: задача, где Q_{tot} **немонотонна** по Q_i :

	$a_2 = L$	$a_2 = R$
$a_1 = U$	8	-12
$a_1 = D$	-12	0

Оптимум $(U, L) = 8$, но QMIX не может представить эту матрицу монотонно

VDN vs QMIX: ограничения монотонности

QMIX строго выразительнее VDN, но **монотонность** всё же ограничивает:

Контрпример: задача, где Q_{tot} **немонотонна** по Q_i :

	$a_2 = L$	$a_2 = R$
$a_1 = U$	8	-12
$a_1 = D$	-12	0

Оптимум $(U, L) = 8$, но QMIX не может представить эту матрицу монотонно

Расширения:

- **WQMIX** — взвешенная проекция, ослабляющая монотонность
- **QTRAN** — полное снятие ограничения, но сложнее в обучении

VDN vs QMIX: ограничения монотонности

QMIX строго выразительнее VDN, но **монотонность** всё же ограничивает:

Контрпример: задача, где Q_{tot} **немонотонна** по Q_i :

	$a_2 = L$	$a_2 = R$
$a_1 = U$	8	-12
$a_1 = D$	-12	0

Оптимум $(U, L) = 8$, но QMIX не может представить эту матрицу монотонно

Расширения:

- **WQMIX** — взвешенная проекция, ослабляющая монотонность
- **QTRAN** — полное снятие ограничения, но сложнее в обучении

На практике QMIX остаётся **стандартным бейзлайном** для кооперативного MARL

Независимый PPO (IPPO)

Самый простой policy gradient подход: каждый агент запускает **PPO** (лекция 6) независимо

Независимый PPO (IPPO)

Самый простой policy gradient подход: каждый агент запускает **PPO** (лекция 6) независимо

Каждый агент i оптимизирует свой клипированный суррогат:

$$L_i^{\text{CLIP}}(\theta_i) = \mathbb{E} \left[\min \left(\frac{\pi_{\theta_i}(a_i|o_i)}{\pi_{\theta_i^{\text{old}}}(a_i|o_i)} \hat{A}_i, \text{clip}(\dots) \hat{A}_i \right) \right]$$

Независимый PPO (IPPO)

Самый простой policy gradient подход: каждый агент запускает **PPO** (лекция 6) независимо

Каждый агент i оптимизирует свой клипированный суррогат:

$$L_i^{\text{CLIP}}(\theta_i) = \mathbb{E} \left[\min \left(\frac{\pi_{\theta_i}(a_i|o_i)}{\pi_{\theta_i^{\text{old}}}(a_i|o_i)} \hat{A}_i, \text{clip}(\dots) \hat{A}_i \right) \right]$$

Почему это работает?

- PPO — on-policy $\Rightarrow$ данные «свежие», ослабляя эффект нестационарности
- Большие батчи стабилизируют обучение
- Клипирование ограничивает размер обновлений

Независимый PPO (IPPO)

Самый простой policy gradient подход: каждый агент запускает **PPO** (лекция 6) независимо

Каждый агент i оптимизирует свой клипированный суррогат:

$$L_i^{\text{CLIP}}(\theta_i) = \mathbb{E} \left[\min \left(\frac{\pi_{\theta_i}(a_i|o_i)}{\pi_{\theta_i^{\text{old}}}(a_i|o_i)} \hat{A}_i, \text{clip}(\dots) \hat{A}_i \right) \right]$$

Почему это работает?

- PPO — on-policy $\Rightarrow$ данные «свежие», ослабляя эффект нестационарности
- Большие батчи стабилизируют обучение
- Клипирование ограничивает размер обновлений

Как и IQL — **удивительно сильный бейзлайн**, часто конкурирует со специализированными методами

MARPO: мультиагентный PPO

Multi-Agent PPO (Yu et al., 2022) — CTDE на основе PPO:

MARPO: мультиагентный PPO

Multi-Agent PPO (Yu et al., 2022) — CTDE на основе PPO:

Архитектура:

- **Централизованный критик:** $V_\phi(s)$ — доступ к глобальному состоянию при обучении
- **Децентрализованные акторы:** $\pi_{\theta_i}(a_i|o_i)$ — только локальное наблюдение

MARPO: мультиагентный PPO

Multi-Agent PPO (Yu et al., 2022) — CTDE на основе PPO:

Архитектура:

- **Централизованный критик:** $V_\phi(s)$ — доступ к глобальному состоянию при обучении
- **Децентрализованные акторы:** $\pi_{\theta_i}(a_i|o_i)$ — только локальное наблюдение

Ключевое отличие от одноагентного PPO: критик видит s (или $(o_1, \dots, o_N)$), акторы — только o_i

MARPO: мультиагентный PPO

Multi-Agent PPO (Yu et al., 2022) — CTDE на основе PPO:

Архитектура:

- **Централизованный критик:** $V_\phi(s)$ — доступ к глобальному состоянию при обучении
- **Децентрализованные акторы:** $\pi_{\theta_i}(a_i|o_i)$ — только локальное наблюдение

Ключевое отличие от одноагентного PPO: критик видит s (или $(o_1, \dots, o_N)$), акторы — только o_i

Практика: MARPO — один из лучших алгоритмов для кооперативного MARL (StarCraft, Hanabi, MPE)

MADDPG: мультиагентный DDPG

Multi-Agent DDPG (Lowe et al., 2017) — off-policy CTDE:

MADDPG: мультиагентный DDPG

Multi-Agent DDPG (Lowe et al., 2017) — off-policy CTDE:

Расширение DDPG (лекция 7):

- **Централизованный критик** для каждого агента: $Q_{\phi_i}(s, a_1, \dots, a_N)$ — видит **все** действия
- **Децентрализованный актор:** $\mu_{\theta_i}(o_i)$ — детерминированная стратегия по o_i

MADDPG: мультиагентный DDPG

Multi-Agent DDPG (Lowe et al., 2017) — off-policy CTDE:

Расширение DDPG (лекция 7):

- **Централизованный критик** для каждого агента: $Q_{\phi_i}(s, a_1, \dots, a_N)$ — видит **все** действия
- **Децентрализованный актор:** $\mu_{\theta_i}(o_i)$ — детерминированная стратегия по o_i

Градиент актора (аналогия с DPG из лекции 7):

$$\nabla_{\theta_i} J(\theta_i) = \mathbb{E} \left[\nabla_{\theta_i} \mu_{\theta_i}(o_i) \cdot \nabla_{a_i} Q_{\phi_i}(s, a_1, \dots, a_N) \Big|_{a_i = \mu_{\theta_i}(o_i)} \right]$$

MADDPG: мультиагентный DDPG

Multi-Agent DDPG (Lowe et al., 2017) — off-policy CTDE:

Расширение DDPG (лекция 7):

- **Централизованный критик** для каждого агента: $Q_{\phi_i}(s, a_1, \dots, a_N)$ — видит **все** действия
- **Децентрализованный актор:** $\mu_{\theta_i}(o_i)$ — детерминированная стратегия по o_i

Градиент актора (аналогия с DPG из лекции 7):

$$\nabla_{\theta_i} J(\theta_i) = \mathbb{E} \left[\nabla_{\theta_i} \mu_{\theta_i}(o_i) \cdot \nabla_{a_i} Q_{\phi_i}(s, a_1, \dots, a_N) \Big|_{a_i = \mu_{\theta_i}(o_i)} \right]$$

Преимущества:

- Работает в **любых** типах игр (кооперация, конкуренция, смешанные)
- Off-policy $\Rightarrow$ эффективность использования данных (replay buffer)

Сравнение: QMIX vs MAPPO vs MADDPG

	QMIX	MAPPO	MADDPG
Тип	value-based	on-policy PG	off-policy PG
Игра	коопер.	коопер.	любая
Действия	дискретные	дискр./непр.	непрерывные
Критик	mixing net	$V(s)$	$Q_i(s, \mathbf{a})$
Ключевая идея	декомпозиция	CTDE + PPO	CTDE + DPG

Сравнение: QMIX vs MAPPO vs MADDPG

	QMIX	MAPPO	MADDPG
Тип	value-based	on-policy PG	off-policy PG
Игра	коопер.	коопер.	любая
Действия	дискретные	дискр./непр.	непрерывные
Критик	mixing net	$V(s)$	$Q_i(s, \mathbf{a})$
Ключевая идея	декомпозиция	CTDE + PPO	CTDE + DPG

Рекомендации:

- **MAPPO** — кооперация, дискретные/непрерывные действия (по умолчанию)
- **QMIX** — кооперация, дискретные действия, нужна декомпозиция
- **MADDPG** — смешанные/конкурентные задачи, непрерывные действия

Коммуникация между агентами

Как агенты могут **обмениваться информацией** при исполнении?

Коммуникация между агентами

Как агенты могут **обмениваться информацией** при исполнении?

CommNet (Sukhbaatar et al., 2016):

- Агенты отправляют непрерывные сообщения
- Каждый агент получает **усреднённое** сообщение от остальных
- Дифференцируемый канал $\Rightarrow$ end-to-end обучение

Коммуникация между агентами

Как агенты могут **обмениваться информацией** при исполнении?

CommNet (Sukhbaatar et al., 2016):

- Агенты отправляют непрерывные сообщения
- Каждый агент получает **усреднённое** сообщение от остальных
- Дифференцируемый канал $\Rightarrow$ end-to-end обучение

TarMAC (Das et al., 2019):

- Механизм **внимания**: агент выбирает, кого слушать
- Soft attention по сообщениям от других агентов

Коммуникация между агентами

Как агенты могут **обмениваться информацией** при исполнении?

CommNet (Sukhbaatar et al., 2016):

- Агенты отправляют непрерывные сообщения
- Каждый агент получает **усреднённое** сообщение от остальных
- Дифференцируемый канал $\Rightarrow$ end-to-end обучение

TarMAC (Das et al., 2019):

- Механизм **внимания**: агент выбирает, кого слушать
- Soft attention по сообщениям от других агентов

DIAL (Foerster et al., 2016):

- **Дискретные** сообщения при исполнении (реалистичнее)
- Непрерывная релаксация при обучении через Straight-Through Estimator

Популяционное обучение и self-play

Self-play: агент играет против копий самого себя

Популяционное обучение и self-play

Self-play: агент играет против копий самого себя

- Противник всегда «на уровне» $\Rightarrow$ автоматический curriculum
- Применяется в играх с нулевой суммой: шахматы, Го, покер

Популяционное обучение и self-play

Self-play: агент играет против копий самого себя

- Противник всегда «на уровне» $\Rightarrow$ автоматический curriculum
- Применяется в играх с нулевой суммой: шахматы, Го, покер

Population-Based Training (PBT, Jaderberg et al., 2019):

- Поддерживаем **популяцию** агентов с разными гиперпараметрами и стратегиями
- Эволюционный отбор: копируем лучших, мутируем параметры
- Разнообразие популяции $\Rightarrow$ робастность к переобучению на одного оппонента

Популяционное обучение и self-play

Self-play: агент играет против копий самого себя

- Противник всегда «на уровне» $\Rightarrow$ автоматический curriculum
- Применяется в играх с нулевой суммой: шахматы, Го, покер

Population-Based Training (PBT, Jaderberg et al., 2019):

- Поддерживаем **популяцию** агентов с разными гиперпараметрами и стратегиями
- Эволюционный отбор: копируем лучших, мутируем параметры
- Разнообразие популяции $\Rightarrow$ робастность к переобучению на одного оппонента

League Training (Vinyals et al., 2019):

- Основные агенты + агенты-эксплойтеры + лига прошлых версий
- Использовано в AlphaStar (подробнее в разделе «Приложения»)

05



Приложения

AlphaStar: StarCraft II

DeepMind, 2019 — уровень грандмастера в StarCraft II

AlphaStar: StarCraft II

DeepMind, 2019 — уровень грандмастера в StarCraft II

Архитектура обучения: League Training

- Популяция агентов: основные (main), эксплойтеры (exploiters), прошлые версии (league)
- Основные агенты обучаются против всей лиги
- Эксплойтеры ищут слабости основных агентов

AlphaStar: StarCraft II

DeepMind, 2019 — уровень грандмастера в StarCraft II

Архитектура обучения: League Training

- Популяция агентов: основные (main), эксплойтеры (exploiters), прошлые версии (league)
- Основные агенты обучаются против всей лиги
- Эксплойтеры ищут слабости основных агентов

Масштаб: ~200 лет игрового опыта, 16 TPU v3

OpenAI Five: Dota 2

OpenAI, 2019 — победа над чемпионами мира по Dota 2

OpenAI Five: Dota 2

OpenAI, 2019 — победа над чемпионами мира по Dota 2

Подход: масштабированный PPO + self-play

- 5 агентов, каждый — отдельная нейросеть (LSTM)
- Централизованное обучение: общая оценка advantage
- ~180 лет игрового опыта **в день**, 256 GPU V100

OpenAI Five: Dota 2

OpenAI, 2019 — победа над чемпионами мира по Dota 2

Подход: масштабированный PPO + self-play

- 5 агентов, каждый — отдельная нейросеть (LSTM)
- Централизованное обучение: общая оценка advantage
- ~180 лет игрового опыта **в день**, 256 GPU V100

Сложности задачи:

- Длинный горизонт (~45 мин, ~20,000 шагов)
- Частичная наблюдаемость («туман войны»)
- ~170,000-мерное пространство наблюдений

Автономное вождение

Автономное вождение — естественная мультиагентная задача:

- Каждый автомобиль — агент со своей целью
- Смешанная мотивация: безопасность (кооперация) + эффективность (конкуренция)

Автономное вождение

Автономное вождение — естественная мультиагентная задача:

- Каждый автомобиль — агент со своей целью
- Смешанная мотивация: безопасность (кооперация) + эффективность (конкуренция)

Применения MARL:

- **Оптимизация перекрёстков:** координация без светофоров
- **Вливание на шоссе:** кооперативное перестроение
- **Моделирование трафика:** симуляция реалистичных водителей

Автономное вождение

Автономное вождение — естественная мультиагентная задача:

- Каждый автомобиль — агент со своей целью
- Смешанная мотивация: безопасность (кооперация) + эффективность (конкуренция)

Применения MARL:

- **Оптимизация перекрёстков:** координация без светофоров
- **Вливание на шоссе:** кооперативное перестроение
- **Моделирование трафика:** симуляция реалистичных водителей

Особенности:

- Безопасность — главный приоритет (constrained MARL)
- Частичная наблюдаемость (окклюзии, ограниченные сенсоры)
- Sim-to-real: обучение в симуляторе, перенос в реальный мир

Роботизированные рои

Децентрализованное управление группой роботов — идеальная задача для Dec-POMDP

Роботизированные рои

Децентрализованное управление группой роботов — идеальная задача для Dec-POMDP

Примеры:

- Складские роботы (Amazon Robotics)
- Дроны: поисково-спасательные операции, картографирование

Роботизированные рои

Децентрализованное управление группой роботов — идеальная задача для Dec-POMDP

Примеры:

- Складские роботы (Amazon Robotics)
- Дроны: поисково-спасательные операции, картографирование

Ограничения реального мира:

- **Коммуникация:** ограниченная пропускная способность, задержки
- **Гетерогенность:** разные типы роботов с разными возможностями
- **Sim-to-real gap:** физика, шумы сенсоров, задержки управления

Роботизированные рои

Децентрализованное управление группой роботов — идеальная задача для Dec-POMDP

Примеры:

- Складские роботы (Amazon Robotics)
- Дроны: поисково-спасательные операции, картографирование

Ограничения реального мира:

- **Коммуникация:** ограниченная пропускная способность, задержки
- **Гетерогенность:** разные типы роботов с разными возможностями
- **Sim-to-real gap:** физика, шумы сенсоров, задержки управления

CTDE — доминирующий подход: централизованное обучение в симуляторе, децентрализованное исполнение на реальных роботах

06



Итоги и открытые вопросы

Дорожная карта алгоритмов MARL

- **Табличные:** IQL, Minimax-Q, Nash-Q, Friend/Foe-Q
- **Глубокие (value):** VDN, QMIX
- **Глубокие (policy):** IPPO, MAPPO, MADDPG
- **Продвинутые:** CommNet, MAT, PBT, League Training

Связь с курсом

Все алгоритмы MARL — расширения методов из лекций 1–7:

Одноагентный	→	Мультиагентный
Q-learning (Л3)	→	IQL, Minimax-Q, Nash-Q
DQN (Л4)	→	VDN, QMIX
Actor-Critic (Л5)	→	MAPPO, MADDPG
PPO (Л6)	→	IPPO, MAPPO
DDPG (Л7)	→	MADDPG

Связь с курсом

Все алгоритмы MARL — расширения методов из лекций 1–7:

Одноагентный	→	Мультиагентный
Q-learning (Л3)	→	IQL, Minimax-Q, Nash-Q
DQN (Л4)	→	VDN, QMIX
Actor-Critic (Л5)	→	MAPPO, MADDPG
PPO (Л6)	→	IPPO, MAPPO
DDPG (Л7)	→	MADDPG

Новое в MARL:

- Теория игр: равновесие Нэша, минимакс, стохастические игры
- CTDE парадигма: централизованный критик / децентрализованные акторы
- Декомпозиция полезности: VDN, QMIX
- Self-play и популяционные методы

Открытые проблемы

1. **Масштабируемость:** 100+ агентов — mean-field подходы, graph-based методы

Открытые проблемы

1. **Масштабируемость:** 100+ агентов — mean-field подходы, graph-based методы
2. **Эмерджентная коммуникация:** могут ли агенты *изобрести* язык?

Открытые проблемы

1. **Масштабируемость:** 100+ агентов — mean-field подходы, graph-based методы
2. **Эмерджентная коммуникация:** могут ли агенты *изобрести* язык?
3. **Теоретические гарантии:** сходимость в общих стохастических играх — открытая проблема

Открытые проблемы

1. **Масштабируемость:** 100+ агентов — mean-field подходы, graph-based методы
2. **Эмерджентная коммуникация:** могут ли агенты *изобрести* язык?
3. **Теоретические гарантии:** сходимость в общих стохастических играх — открытая проблема
4. **Безопасность:** координация без катастрофических сбоев, устойчивость к враждебным агентам

Открытые проблемы

1. **Масштабируемость:** 100+ агентов — mean-field подходы, graph-based методы
2. **Эмерджентная коммуникация:** могут ли агенты *изобрести* язык?
3. **Теоретические гарантии:** сходимость в общих стохастических играх — открытая проблема
4. **Безопасность:** координация без катастрофических сбоев, устойчивость к враждебным агентам
5. **Перенос и обобщение:** перенос стратегий на новых оппонентов / новые задачи

Открытые проблемы

1. **Масштабируемость:** 100+ агентов — mean-field подходы, graph-based методы
2. **Эмерджентная коммуникация:** могут ли агенты *изобрести* язык?
3. **Теоретические гарантии:** сходимость в общих стохастических играх — открытая проблема
4. **Безопасность:** координация без катастрофических сбоев, устойчивость к враждебным агентам
5. **Перенос и обобщение:** перенос стратегий на новых оппонентов / новые задачи
6. **Real-world deployment:** sim-to-real gap, ограниченная коммуникация, гетерогенность

Вопросы?